

VÍTOR WILHER

Engenheiro de IA Sênior — Agentes, LLMs em Produção e RAG / Professor de IA Generativa (MBA)

Contatos

Endereço: Rua Professor Azevedo Marques, 15, Apto 405, Leblon, Rio de Janeiro

E-mail: vtorwilher@analisemacro.com.br

Telefone: +55 (21) 96721-6813

Linkedin: linkedin.com/in/vitorwilher

Portfólio: vitorwilher.github.io

Resumo das Habilidades

Engenheiro de IA com formação sólida em Economia e Estatística, atuando no ciclo completo de produtos de IA Generativa — refinamento técnico, decisões de arquitetura, implementação, *deploy* e sustentação em produção. Constrói **agentes de IA em operação contínua**: *tool use/function calling*, *structured outputs* com **JSON Schema**, RAG híbrido (BM25 + denso, fusão RRF e *reranking*), integração com **APIs REST** e sistemas de terceiros, e entrega em canais reais — incluindo **WhatsApp Business (Meta Cloud API)** com *templates* aprovados e **TTS**. Trata qualidade como engenharia: **guardrails** e *gates human-in-the-loop* contra alucinação, *eval harness* com *golden set* e **LLM-as-judge** que **reprova regressão no CI**, e **observabilidade de custo por token, latência e qualidade por execução**. Opera **multi-provedor** (Anthropic, OpenAI, Google; Amazon Bedrock) escolhendo modelo por qualidade × custo × latência, e publica **servidores MCP (Model Context Protocol)**. Traduz necessidade de negócio em solução técnica e comunica com públicos executivos — é professor de IA Generativa em MBA. Bacharel e Mestre em Economia (UFF), Especialista em Análise de Dados e IA, Candidato ao PhD em Economia pela EPGE/FGV. Especialista em IA Generativa da Análise Macro e Especialista em Tecnologia e Dados do SENAC Rio.

Hard Skills: **Python** (principal, orientação a objetos e boas práticas de engenharia), R, SQL, TypeScript, **FastAPI**, **Docker**, Git, **CI/CD (GitHub Actions, GitLab CI)**, testes automatizados e de integração (**pytest**), Clean Code e padrões de projeto; LLMs e API programática (**Anthropic Claude, OpenAI, Google Gemini, Amazon Bedrock**), **agentes e orquestração** (LangChain, Claude Agent SDK, grafos de estado com roteamento dinâmico), *function calling/tool use*, *structured outputs/JSON Schema* e validação de respostas, **prompt caching**, **Prompt e Context Engineering**, fluxos *human-in-the-loop*; **RAG** e *vector databases* (ChromaDB, pgvector, BM25/embeddings, RRF, *reranking*); **guardrails**, mitigação de alucinação e segurança aplicada a LLMs (*text-to-SQL* seguro, gestão de *secrets*, credenciais de escopo mínimo); **avaliação e observabilidade de LLMs** (*golden set*, LLM-as-judge, *self-consistency*, LangSmith, QA-Eval, *gate* de CI, custo/latência/tokens por *request*); **MCP (Model Context Protocol)** — construção e publicação de servidores; **fine-tuning (LoRA/QLoRA)**, NLP, Machine Learning (Scikit-learn, Pandas, NumPy), Deep Learning, **foundation models de séries temporais** (Chronos, TimeGPT), Econometria e Inferência Estatística (OLS/HAC, GMM, VAR/VECM, filtro de Kalman, bootstrap); **Cloud** (AWS — EC2, Lambda, S3, SageMaker AI, DynamoDB, Aurora, Redshift, Bedrock; Google Cloud Storage; Cloudflare Workers), **PostgreSQL**, DuckDB, Parquet, orquestração de pipelines e filas.

Soft Skills: liderança técnica de projetos, comunicação com públicos técnicos e não-técnicos, mentoria de desenvolvedores, criatividade, trabalho em equipe, bom humor.

Principal Interesse atual: engenharia de agentes de IA em produção — jornadas conversacionais integradas a APIs e sistemas corporativos, com guardrails, avaliação contínua e observabilidade de custo, latência e qualidade — aplicada a economia, finanças e mercado financeiro.

Formação Educacional

Doutorado em Economia

EPGE/FGV · 2026-2030

- Tese sobre o uso de **foundation models para previsão de variáveis macroeconômicas** — capacidade preditiva *zero-shot* de modelos fundacionais de séries temporais (Amazon **Chronos**, Nixtla **TimeGPT**) frente a modelos econométricos e de *machine learning* na previsão de IPCA, câmbio, PIB e Selic;
- Investiga o ganho marginal de *ensembles* que combinam modelos fundacionais, ML clássico e **sinais textuais extraídos por LLMs** da comunicação do Banco Central, com avaliação estatística formal (Diebold-Mariano, Mincer-Zarnowitz) contra o Boletim Focus;
- Base empírica implementada e em operação contínua no projeto **Previsão Macro** (previsões publicadas e reavaliadas a cada ciclo desde 2026).

Pós-Graduação em LLMs e IA Generativa

PUC-RIO · 2025-2026

- Trabalho de Conclusão de Curso sobre o **ROI Diagnóstico** — plataforma de inteligência comercial que integra seis APIs de negócio e camadas de IA Generativa para diagnóstico e decisão em um negócio digital real;
- O sistema já opera em produção: pipeline diário orquestrado, *data warehouse* analítico em Parquet/DuckDB, agentes de monitoramento que sintetizam desempenho de campanhas com LLM e entregam relatórios automáticos via **WhatsApp Business API**, além de módulos de diagnóstico financeiro (DRE e fluxo de caixa) sobre a operação.

Mestrado em Economia

UFF · 2013-2015

- Atividades e grupos: Coordenador do Grupo de Estudos sobre Conjuntura Econômica (GECE/UFF);
- Tutor da disciplina Conjuntura e Cenários Macroeconômicos;
- Dissertação defendida com o título “Clareza da Comunicação do Banco Central e Expectativas de Inflação: evidências para o Brasil” perante banca composta pelos professores Gustavo H. B. Franco, Gabriel Montes Caldas, Luciano Vereda Oliveira e Carlos Enrique Guanziroli.

Graduação em Economia

UFF · 2010-2012

- Monitor da disciplina Macroeconomia I
- Monografia de Final de Curso: A nova política monetária brasileira no contexto da grande recessão.

Graduação em Economia

UFRRJ · 2007-2009

Técnico de Telecomunicações

ETE Ferreira Viana · 1998-2000

Experiência Profissional

Especialista em Tecnologia e Dados

SENAC RJ · 2026-Atual

- Especialista em Dados e IA Generativa com atuação na Célula de Inovação do SENAC, sendo o responsável pelo portfólio de Cursos e Projetos em engenharia, ciência, análise de dados, IA Generativa e Cloud para todo o Estado do Rio de Janeiro;
- Concepção e desenvolvimento do **Agente de Validação Pedagógica de materiais do ETIM**: pipeline agêntico em **Python + API Anthropic (Claude)** com *tool use* (**web search** para checagem de fontes), *structured outputs* (JSON schema), *prompt caching* e *system prompt* versionado, que valida e reescreve materiais didáticos preservando a autoria do conteudista — com **gate human-in-the-loop** que impede que conteúdo autorado pela IA vire entrega sem revisão do especialista;
- **Eval harness** do agente com *golden set* (8 pares “insumo → validação humana”), rubrica multicritério por **LLM-as-judge**, controle negativo de preservação e relatório por critério — **evals e testes de regressão** como critério de aceite de cada mudança de prompt, com observabilidade de custo, tokens e latência por execução.

Professor de IA Generativa

Impacta Tecnologia · Mar 2026-Jul 2026

- **Transformers e LLMs** (Master em IA): arquitetura Transformer e *self-attention*, pré-treino e RLHF, multimodalidade, e a cadeia de valor econômica dos LLMs — do modelo como serviço à decisão de *build vs. buy*;
- **AI Applications** (MBA em IA): disciplina de fechamento do programa, conduzida como laboratório aplicado — design de soluções de IA orientadas a valor, integração de **ML + LLMs + dados + automação**, prototipagem e **defesa da solução para stakeholders executivos**, com entrega final avaliada como produto de ponta a ponta;
- Tradução de arquitetura técnica de IA para público executivo — competência aplicada diretamente em decisões de custo, risco e viabilidade de soluções.

Especialista em IA Generativa

Análise Macro · 2015-Atual

- Liderança técnica no ciclo completo de produtos de IA Generativa e ML — refinamento, decisões de arquitetura, implementação, *deploy* e sustentação em produção —, atuando como interlocutor entre necessidades de negócio e implementação técnica;
- Desenvolvimento de agentes de IA com **RAG** (recuperação híbrida BM25 + densa, fusão RRF e *reranking*), orquestração com LangChain e engenharia de prompts, servidos como **API REST em FastAPI** e empacotados em **Docker** — como o serviço de consulta às atas do COPOM, com *eval harness* (*golden set* + LLM-as-judge), **gate de qualidade que reprova regressões no CI e observabilidade de custo, latência e tokens por request**;
- Construção e sustentação de **agentes em produção contínua** que integram LLM a APIs de terceiros e entregam em canais transacionais — pipeline semanal que coleta fontes por **IMAP e RSS**, sintetiza com Claude (*streaming, adaptive thinking*), renderiza documento e entrega via **WhatsApp Business Cloud API** com *templates* aprovados, mais geração de áudio por **TTS** publicada como *link* — tudo orquestrado em **GitHub Actions**, com execução sob demanda por *workflow dispatch* e **degradação segura** (cada etapa falha isolada, sem quebrar a entrega nem fabricar conteúdo);
- Concepção e publicação do **primeiro servidor MCP (Model Context Protocol) da empresa**, em **TypeScript sobre Cloudflare Workers**: expõe as séries analíticas do IPCA como ferramentas que assistentes de IA (Claude, Cursor, Codex) consomem ao vivo, com atualização mensal automática e sem autenticação para o usuário final;
- Construção de sistemas **multi-LLM / multi-agente** para análise de sentimento das atas do COPOM — três provedores em paralelo (**Anthropic, Google e OpenAI**), com validação cega por agentes independentes e agregação por *self-consistency*, seleção de modelo por **qualidade x custo x latência** e saídas validadas contra *schema*;
- Arquitetura e operação do **ROI Diagnóstico**, plataforma de inteligência comercial que integra **seis APIs REST** de negócio (e-commerce, gateway de pagamento, *ads*, analytics, CRM e e-mail marketing) em pipeline diário orquestrado, com validação de contrato por *schema* (Pandera), **DuckDB sobre Parquet** em nuvem e camada de agentes que sintetiza desempenho com LLM e entrega relatórios recorrentes via **WhatsApp Business API**;
- Autoria do pacote R **nucleos** (código aberto), que reproduz as séries analíticas do IPCA publicadas pelo Banco Central (Nota Técnica 57) com **conformidade verificada em testes automatizados contra a série oficial do SGS**;
- Avaliação e observabilidade de modelos e pipelines de IA: *LLM-as-judge*, LangSmith e QA-Eval para *evals* e testes de regressão; validação estatística de previsões (Diebold-Mariano, Mincer-Zarnowitz) contra o Boletim Focus do Banco Central;
- Pipelines preditivos combinando **ML clássico** (Scikit-learn/ **skforecast**) e **foundation models** (Amazon Chronos, Nixtla TimeGPT) em *ensembles* para IPCA, câmbio, juros e PIB, publicados em *dashboard* com **CI/CD via GitHub Actions** (*cache* de pesos, controle de concorrência) e reavaliados a cada ciclo;
- Estudos de **fine-tuning (LoRA/QLoRA)** de modelos abertos para extração estruturada de indicadores de *releases* do BCB/IBGE, com *benchmark* próprio contra *baselines zero-shot* via API — avaliando a troca entre custo de inferência e acurácia em tarefa estreita;

- Construção e automatização de pipelines de ETL com SQL, Python e R para coleta e tratamento de dados econômico-financeiros de fontes como B3, Banco Central e SIDRA/IBGE, com rastreabilidade das execuções;
- Liderança técnica e curadoria do acervo do **Clube AM**: mais de 40 cursos e **700 exercícios aplicados publicados** (Python, R e SQL), dos quais **91 dedicados a Inteligência Artificial** — incluindo a trilha de LLMs aplicados a economia e finanças (índice de sentimento do Copom com LLMs, RAG sobre documentos econômicos, agentes de IA e previsão com IA) —, com coordenação e mentoria da equipe de autores;
- Prestação de consultoria em análise de dados e IA para empresas do mercado financeiro; aplicação de metodologias ágeis para a criação de novos produtos digitais.

Membro do Comitê de Gestão

Instituto Millenium · 2008-2018

- Atuou como membro do Conselho de Gestão da instituição;
- Ministrou palestras em todo o Brasil sobre perspectivas econômicas e análise de dados.

Professor

Universidade Veiga de Almeida · 2015-2015

- Professor de Matemática e Estatística nos cursos de MBA da instituição.

Coordenador

GECE/UFF · 2013-2014

- Coordenei alunos de graduação no desenvolvimento de análises de perspectivas econômicas;
- Organizei e apresentei palestras com palestrantes renomados, incluindo o Professor Gustavo Franco e a Professora Monica de Bolle.

Estagiário Middle Office Comercial

Endesa · 2009-2010

Atuação no middle office da área comercial da Endesa Geração de Energia. A atividade principal envolvia a elaboração de estudos e relatórios sobre o mercado de energia elétrica brasileiro, com o auxílio de modelos matemáticos (NEWAVE, principalmente) e acesso a regulamentos da ANEEL e da CCEE e publicações da EPE e da ONS. Além disso, era responsável pela elaboração de microestudos sobre a viabilidade financeira de operações de compra e venda de energia elétrica, sempre comparando o negócio proposto com o custo de oportunidade, representado pelo PLD. Fiz uso intensivo de macros e VBA no Excel, além de operação do NEWAVE, modelo matemático responsável por gerar cenários de tendência para o preço da energia elétrica no Brasil.

Estagiário

Incubadora de Empresas COPPE/UFRJ · 2009-2009

Atuação como Estagiário de Economia na assessoria econômico-financeira às empresas incubadas e na implementação e gerenciamento do Desafio Universitário Empreendedor Sebrae.

Estagiário

RC Consultores · 2008-2008

Atuação como Estagiário de Economia, auxiliando na coleta e tratamento de dados macroeconômicos.

Estagiário

Brechbuhler Consultoria · 2008-2008

Atuação como Estagiário de Economia na elaboração de rotinas de administração financeira de uma empresa (fluxo de caixa, DRE, balanço patrimonial etc.); elaboração de business plan; estruturação e obtenção de financiamento de longo prazo junto ao BNDES; estudos de viabilidade econômica; concepção e estruturação de project finance, dentre outras atividades correlacionadas.

Técnico de Gerência de Redes Sr

Oi/Telemar · 2000-2007

Trabalhou na Gerência de Redes Nacional da operadora, como especialista na programação de centrais telefônicas de grande porte EWSD/Siemens. As atividades principais envolviam a configuração das centrais EWSD/Siemens da planta e resolução de falhas da rede doméstica (voz e sinalização) envolvendo principalmente protocolos TUP, ISUP e MFC-R2. Também era responsável pelo suporte e treinamento a outros membros da equipe. As habilidades necessárias eram saber programar em CHILL, conhecer redes/protocolos de telecomunicações e hardware da central EWSD/Siemens.

Projetos Selecionados

ROI Diagnóstico — plataforma de inteligência comercial que sustenta a operação de um negócio digital de ponta a ponta (*repositório privado*). Integra **seis APIs REST** (WooCommerce, Pagar.me, Meta Ads, Google Analytics 4, CRM e e-mail marketing) em pipeline diário orquestrado por **GitHub Actions**, com validação de contrato por *schema* (**Pandera**), *refresh* incremental com deduplicação, persistência em **Parquet no Google Cloud Storage** e consultas analíticas em **DuckDB** — servido em *dashboard* interativo. Sobre essa base roda uma camada de **agentes de monitoramento** que sintetizam desempenho de campanhas e finanças com LLM e entregam relatórios recorrentes via **WhatsApp Business Cloud API** (*templates* aprovados), além de módulos de **DRE e fluxo de caixa** sobre a operação real. Base do TCC da pós-graduação em LLMs e IA Generativa (PUC-Rio).

Newsletter Digest Bot — agente de IA em **produção contínua desde abril/2026**, entregando sem intervenção humana toda semana. Coleta um corpus heterogêneo via **IMAP** e **feeds RSS** (arXiv, RePEc, NBER), sintetiza com **Claude Opus** (*streaming, adaptive thinking, system prompt* versionado), injeta seções curadas de fontes externas via **MCP**, renderiza PDF e entrega no **WhatsApp Business Cloud API**; um segundo fluxo gera **podcast** com **TTS** multi-voz publicado como *link*. Suporta **execução sob demanda** por *workflow dispatch* (dossiê vertical sobre tema escolhido) e foi projetado para **degradação segura**: cada etapa falha isolada, sem quebrar a entrega e **sem fabricar conteúdo** — com normalização de fontes que corrige links quebrados na origem. Orquestrado em GitHub Actions, credenciais por *secrets* e **deploy key de escopo mínimo** (*repositório privado*).

Previsão Macro — pipeline reprodutível que publica previsões de **IPCA, câmbio, PIB e Selic** em *dashboard* atualizado automaticamente. Combina em *ensemble* modelos econométricos e de ML (**skforecast**/Scikit-learn) com dois **foundation models de séries temporais** — Amazon **Chronos** (aberto, *zero-shot*) e Nixtla **TimeGPT** (proprietário, com exógenas e intervalos quantílicos) — e um modelo dedicado à Selic que usa como exógena o **índice de tom das atas do Copom extraído por três LLMs**. Três *workflows* de CI/CD encadeados, com *cache* de pesos e controle de concorrência. Base empírica da tese de doutorado (EPGE/FGV). vitorwilher.shinyapps.io/previsao_macro

MCP Análise Macro — servidor **MCP** público que leva as séries analíticas do IPCA (Nota Técnica 57 do BCB) para dentro do Claude, Cursor e Codex. TypeScript sobre Cloudflare Workers, sem autenticação, com atualização mensal automática. Primeiro MCP da empresa. nucleos-mcp.analisemacro.workers.dev

nucleos — pacote R de código aberto que reproduz as 22 séries analíticas do IPCA do Banco Central, com conformidade verificada em testes automatizados contra a série oficial do SGS. github.com/vitorwilher/nucleos

Agente de Validação Pedagógica ETIM (SENAC RJ) — agente de IA em produção que valida materiais didáticos contra as regras pedagógicas do programa. Python + API Anthropic com *tool use* (web search), *structured outputs* e *prompt caching*; **gate human-in-the-loop** e *eval harness* com *golden set* e LLM-as-judge.

COPOM RAG Service — RAG sobre as atas do Copom e o Focus servido como **API REST** (FastAPI + Docker), com **recuperação híbrida BM25 + densa, fusão RRF e reranking**, respostas **com fontes citadas** como *guardrail* contra alucinação numérica, e *eval harness* — *golden set*, LLM-as-judge com *self-consistency* e **gate de CI que reprova regressão de qualidade** — além de observabilidade de **custo, latência e tokens por request**. github.com/vitorwilher/copom-rag-service

Sentimento COPOM & Regra de Taylor — índice de tom *hawkish-dovish* das atas construído com três LLMs em paralelo e validação cega por agentes independentes, usado como regressor em uma Regra de Taylor aumentada (OLS/HAC, GMM, VAR/VECM, filtro de Kalman). vitorwilher.github.io

Idiomas

Inglês — Nível Avançado

Espanhol — Nível Intermediário

Habilidades Principais

- Python (OO, Clean Code, pytest)
- LLMs em produção (Anthropic, OpenAI, Google, Bedrock)
- Agentes de IA e orquestração (LangChain, Claude Agent SDK)
- *Function calling* / *tool use*
- *Structured outputs* e JSON Schema
- RAG (híbrido BM25 + denso, RRF, *reranking*)
- Guardrails e mitigação de alucinação
- Avaliação de LLMs (*golden set*, LLM-as-judge, gate de CI)
- Observabilidade (custo/token, latência, qualidade)
- Prompt e Context Engineering
- APIs REST (FastAPI) e integrações corporativas
- WhatsApp Business Cloud API
- Docker, CI/CD (GitHub Actions, GitLab CI)
- Cloud (AWS, GCP, Cloudflare Workers)
- SQL / PostgreSQL / DuckDB
- MCP (Model Context Protocol)
- *Foundation models* de séries temporais
- Machine Learning (Scikit-learn) e *fine-tuning* (LoRA/QLoRA)
- Econometria e Inferência Estatística
- Comunicação executiva e liderança técnica