Transformers Models

Large Language Models (LLMs)

Aula 01 – 26 de Abril de 2026

Vítor Wilher

Data Tech Lead na Análise Macro

Plano de Voo

- Sobre o Professor
- Sobre o Curso
- Referências
- LLMs dentro do contexto geral da Inteligência Artificial
- Oportunidades
- De Modelos de Linguagem a Grandes Modelos de Linguagem
- Dos LLMs aos “Modelos de Fundação”
- Casos de Uso

Sobre o Professor

Líder Técnico de Dados com sólida formação em Economia e Estatística e experiência prática em análise de dados econômicos e financeiros usando R, Python e IA Generativa.

É Bacharel e Mestre em Economia pela Universidade Federal Fluminense, Especialista em Análise de Dados e Inteligência Artificial e Candidato ao PhD em Economia pela EPGE/FGV.

Fundador e Líder Técnico de Dados da Análise Macro, uma EdTech com 10 anos de existência, nascida do inconformismo com o ensino tradicional oferecido pelas faculdades de economia no Brasil.

Ementa Resumida do Curso

Detalhar a arquitetura *Transformer* e os *LLMs* — a tecnologia específica que impulsionou a revolução da **IA generativa** em linguagem.

Compreender como esses modelos funcionam é essencial para usá-los estrategicamente.

Temas Abordados

Panorama Geral da IA: cronologia e oportunidades;

A arquitetura Transformer: atenção, tokens e embeddings (sem matemática);

Como LLMs são treinados: dados, RLHF e alinhamento com intenção humana

Capacidades emergentes: raciocínio, geração de código e multimodalidade;

Contexto e memória: limitações de janela de contexto e estratégias de contorno;

Principais LLMs do mercado: GPT, Claude, Gemini, Llama — diferenças e posicionamento.

Ao fim da disciplina, espera-se que...

O aluno entenderá como os **LLMs** funcionam internamente, quais são suas capacidades reais e limitações, e como esse conhecimento impacta decisões de adoção, customização e integração em produtos e processos.

Planejamento das Aulas
Horário: 19h às 22h40

AULA 01 – 26 DE MARÇO

AULA 02 – 31 DE MARÇO

AULA 03 – 02 DE ABRIL

AULA 04 – 7 DE ABRIL

Avaliação

- Trabalho aplicado sobre temas vistos na disciplina (80% da nota);
- **Participação nas aulas (20% da nota);**

- O Trabalho será postado no Classroom até o próximo dia 3 de abril.

- Os alunos terão até o dia **17 de abril** para entregarem via Classroom.

Referências

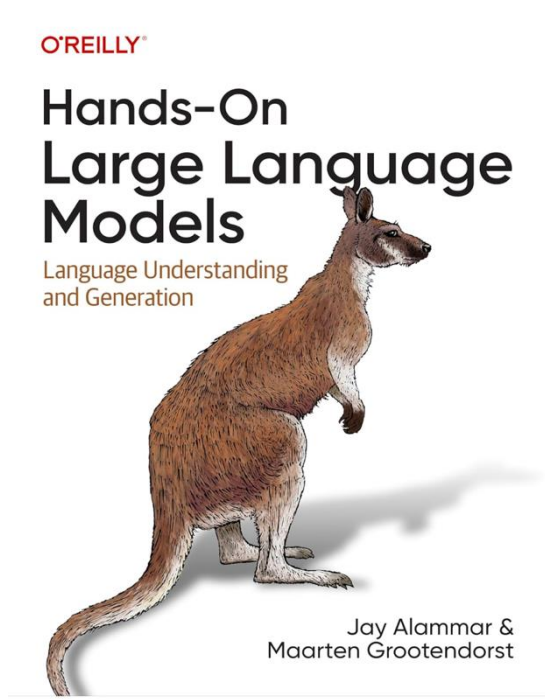

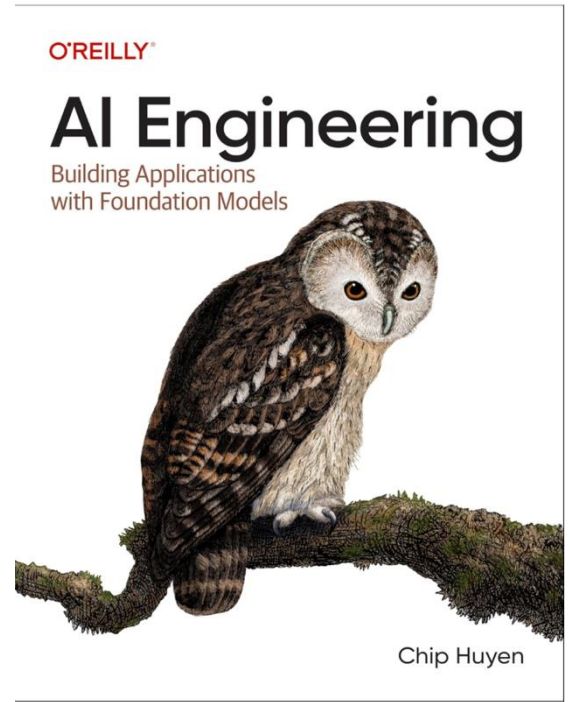

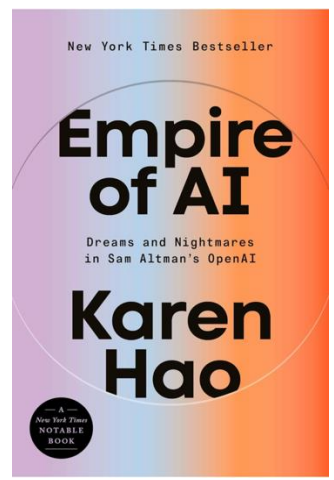

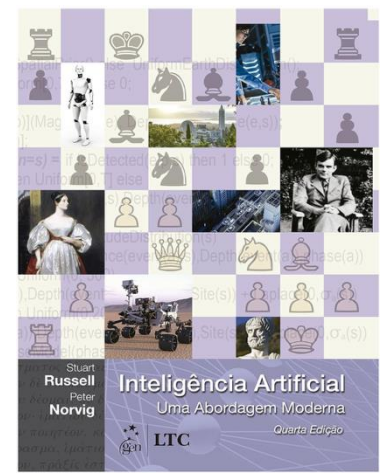

Onde estamos

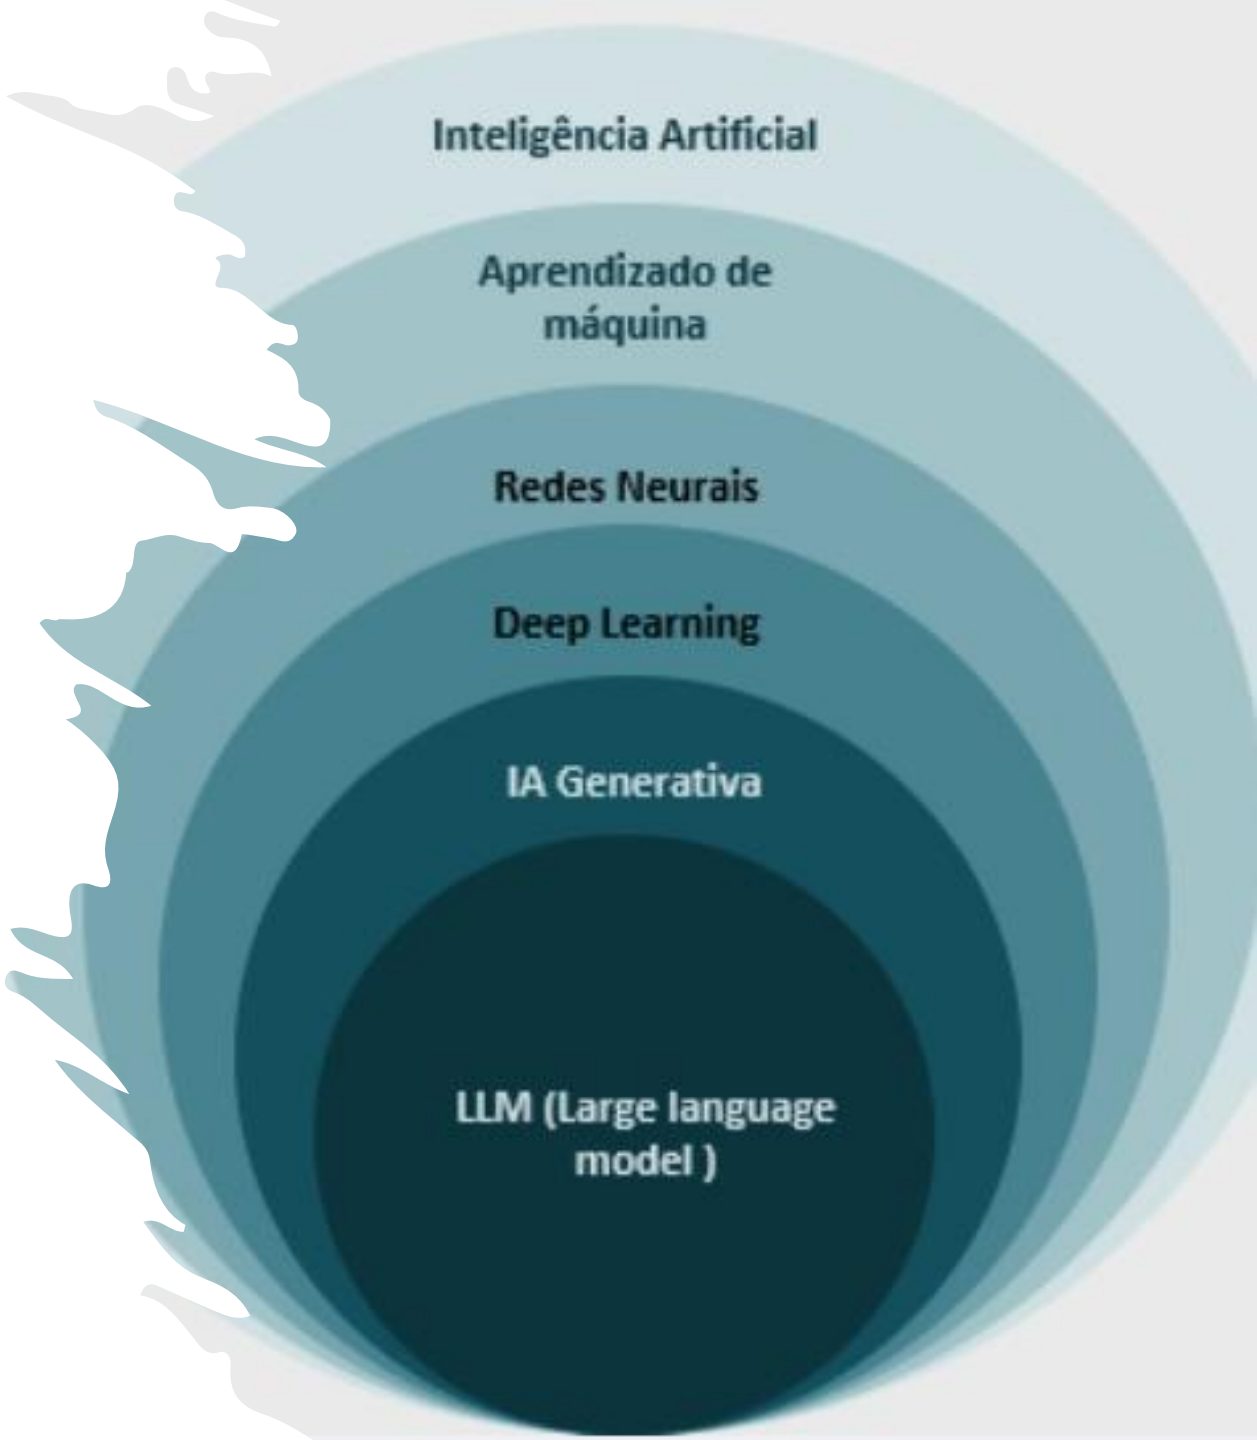

O que é Inteligência Artificial?

Inteligência Artificial é qualquer sistema que consegue “pensar” ou tomar decisões como um humano.

- **Exemplo:**
- Recomendações da Netflix
- Waze sugerindo rotas
- ChatGPT respondendo você

IA não é mágica. É estatística com ambição.

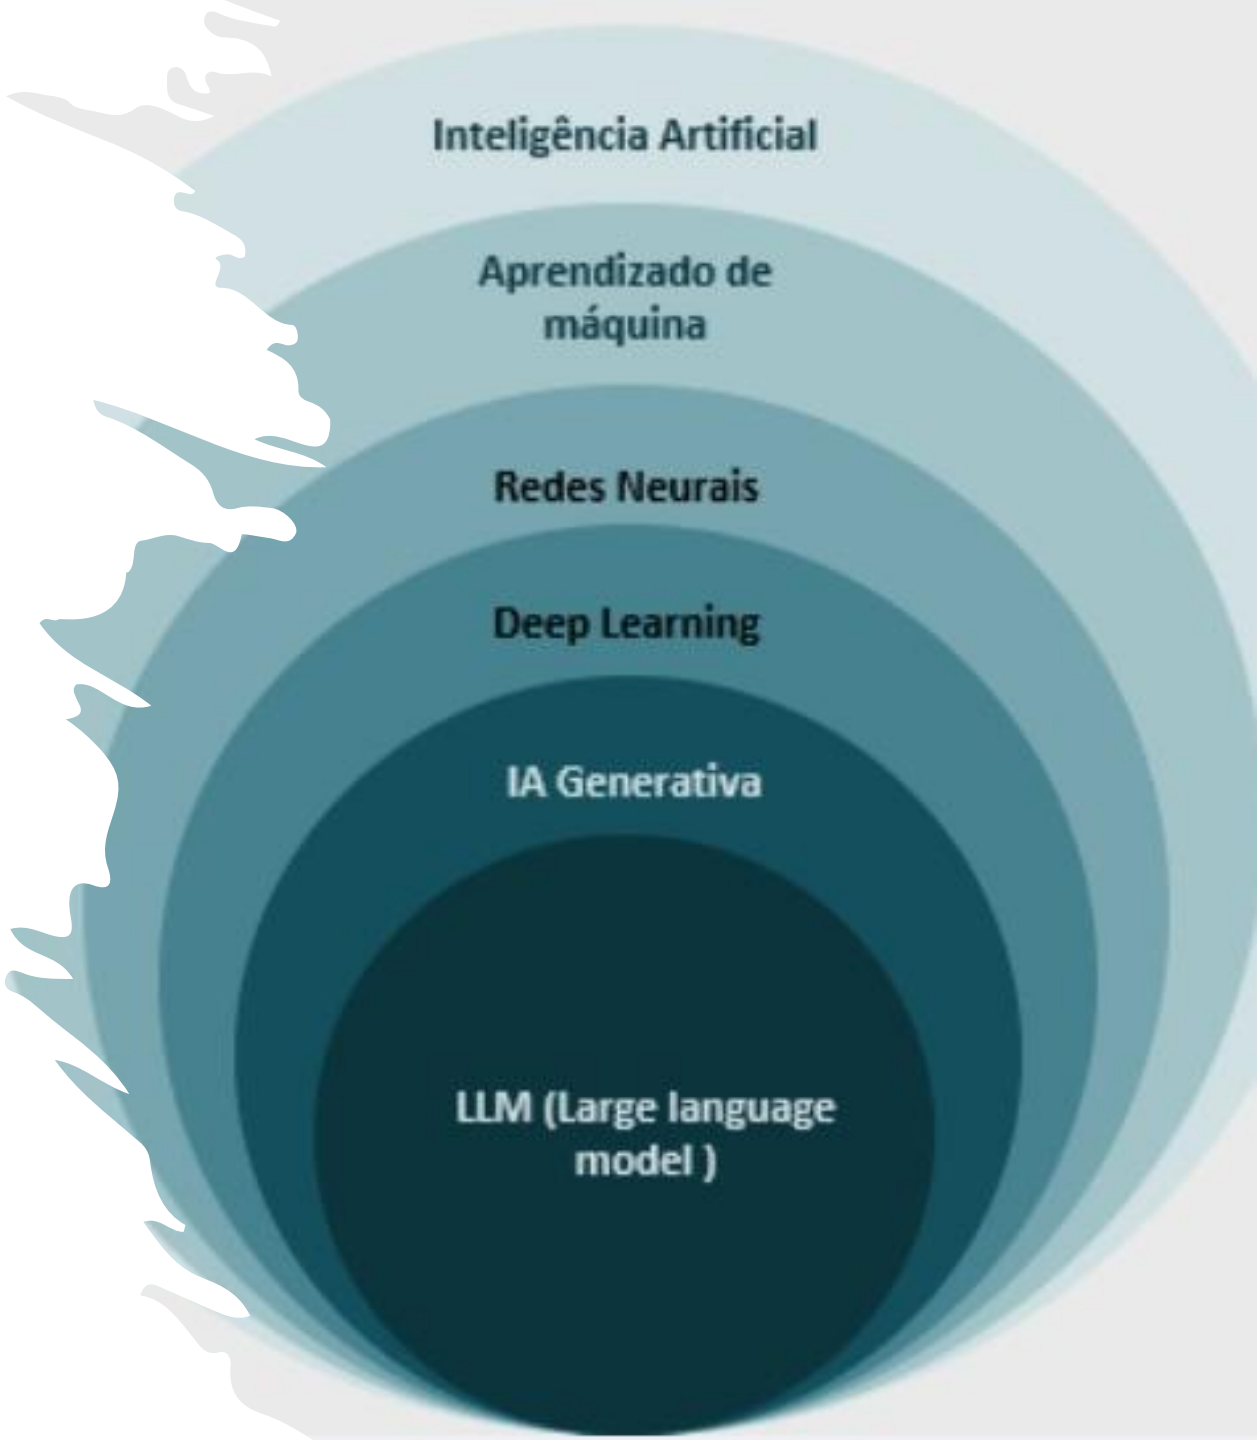

Aprendizado de Máquina (Machine Learning)

Aqui a máquina não recebe regras prontas. Ela aprende com dados.

- **Exemplo:**
  Você mostra milhares de casos →
  ela aprende padrões →
  faz previsões
- **Exemplo real:**
  Prever inflação, churn, preço de ações

Não programamos respostas.
Programamos aprendizado.

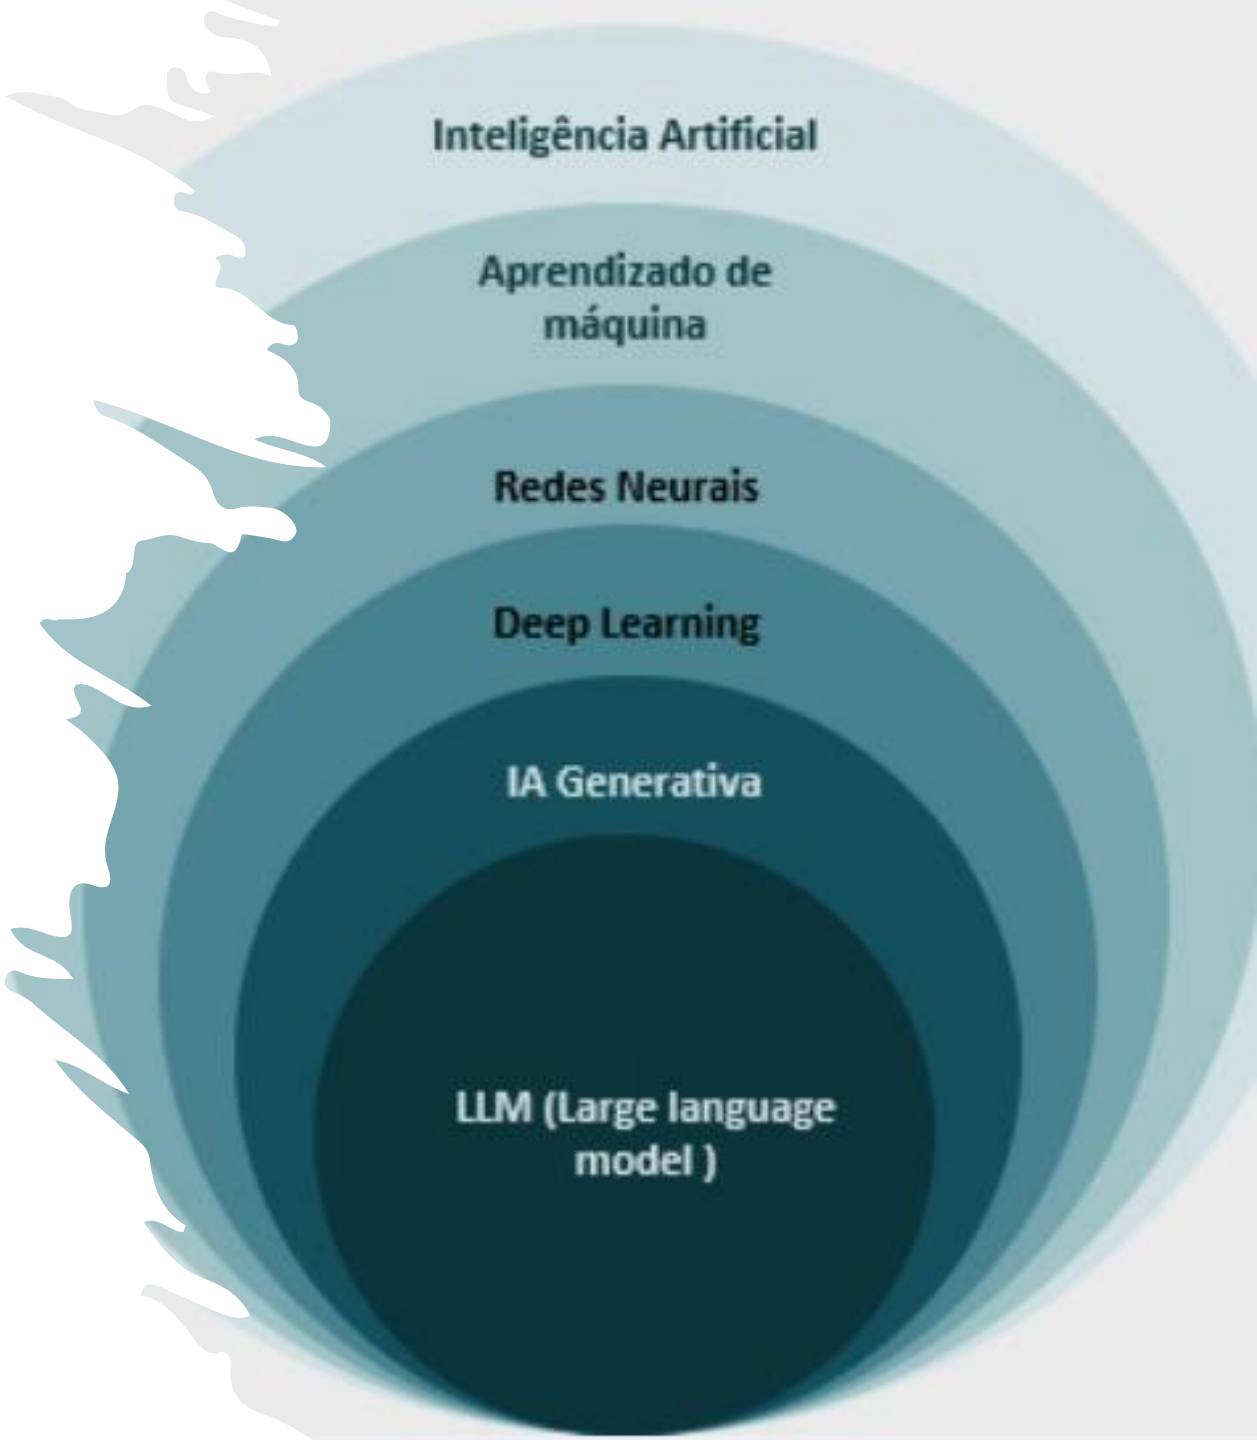

Redes Neurais

Inspiradas no cérebro humano.
São modelos que conectam “neurônios artificiais” para aprender padrões complexos.

- **Exemplo:**
  Reconhecimento de imagem, voz, texto
- **Imagem mental:**
  Uma rede de decisões interligadas

Aqui a coisa começa a ficar poderosa... e menos interpretável.

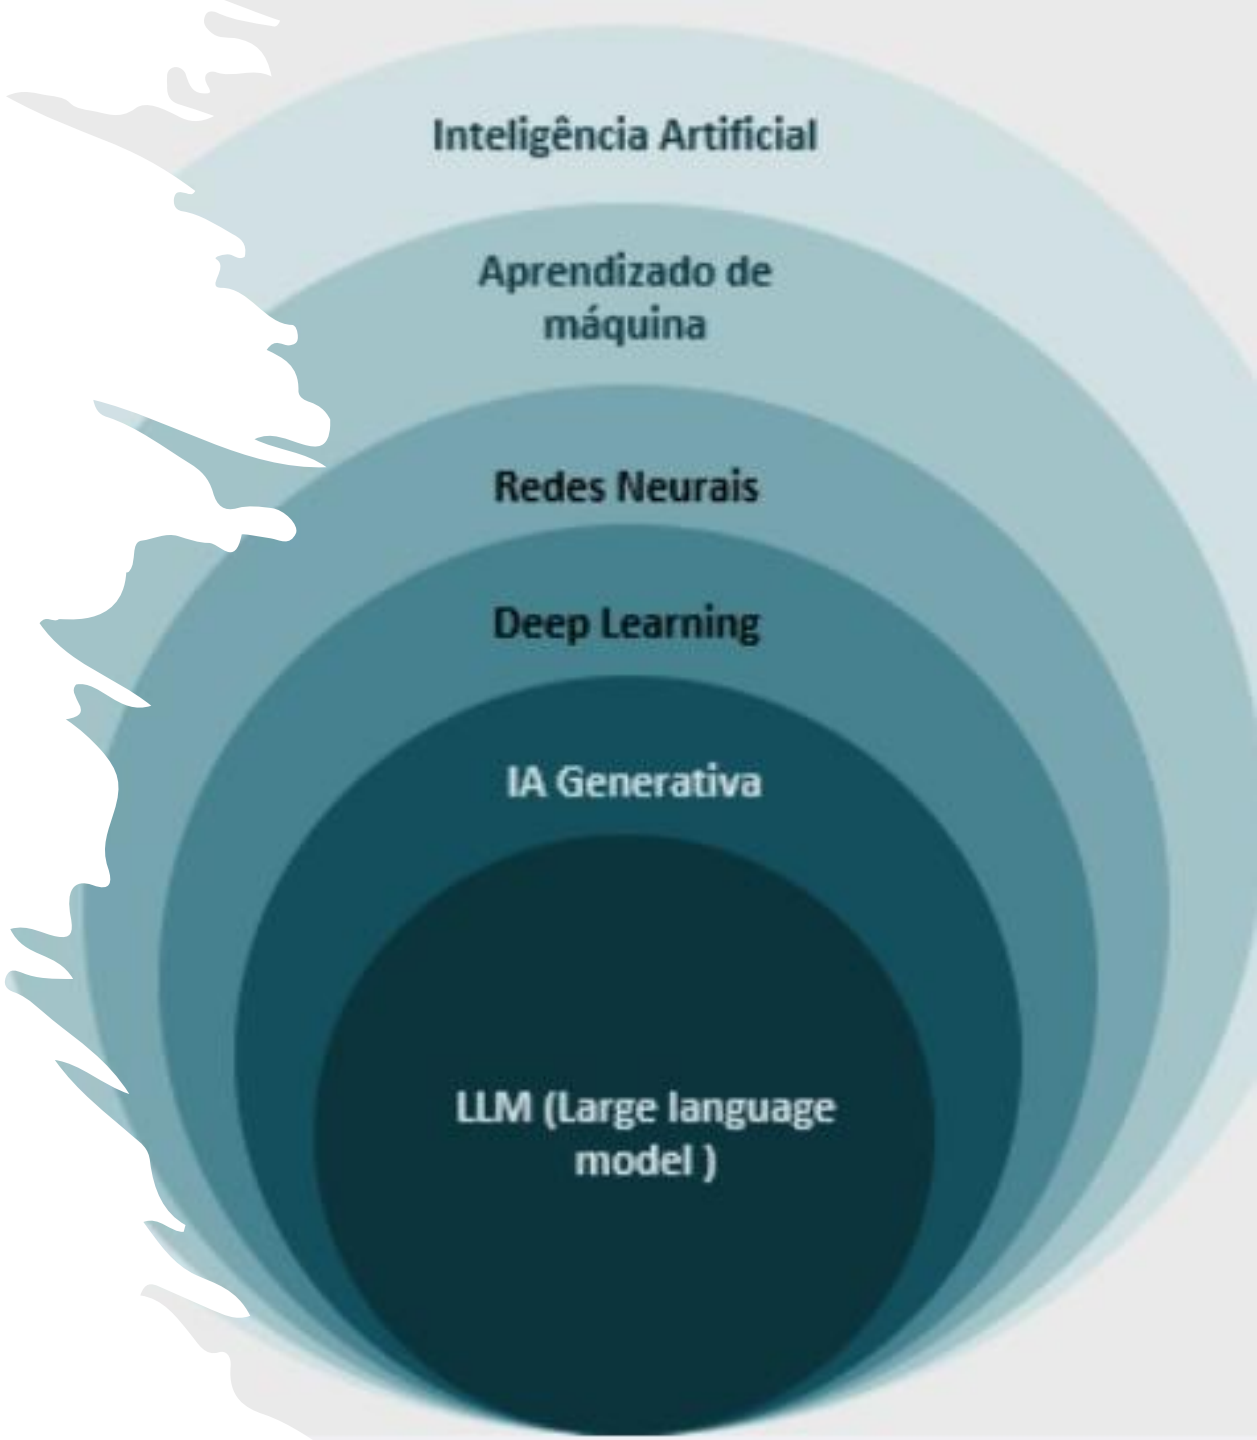

Deep Learning

São redes neurais... só que MUITO maiores e mais profundas.

Mais camadas → mais capacidade de aprender padrões complexos

- **Exemplo:**
- Reconhecimento facial
- Tradução automática
- Direção autônoma

Mais dados + mais poder computacional = mais inteligência

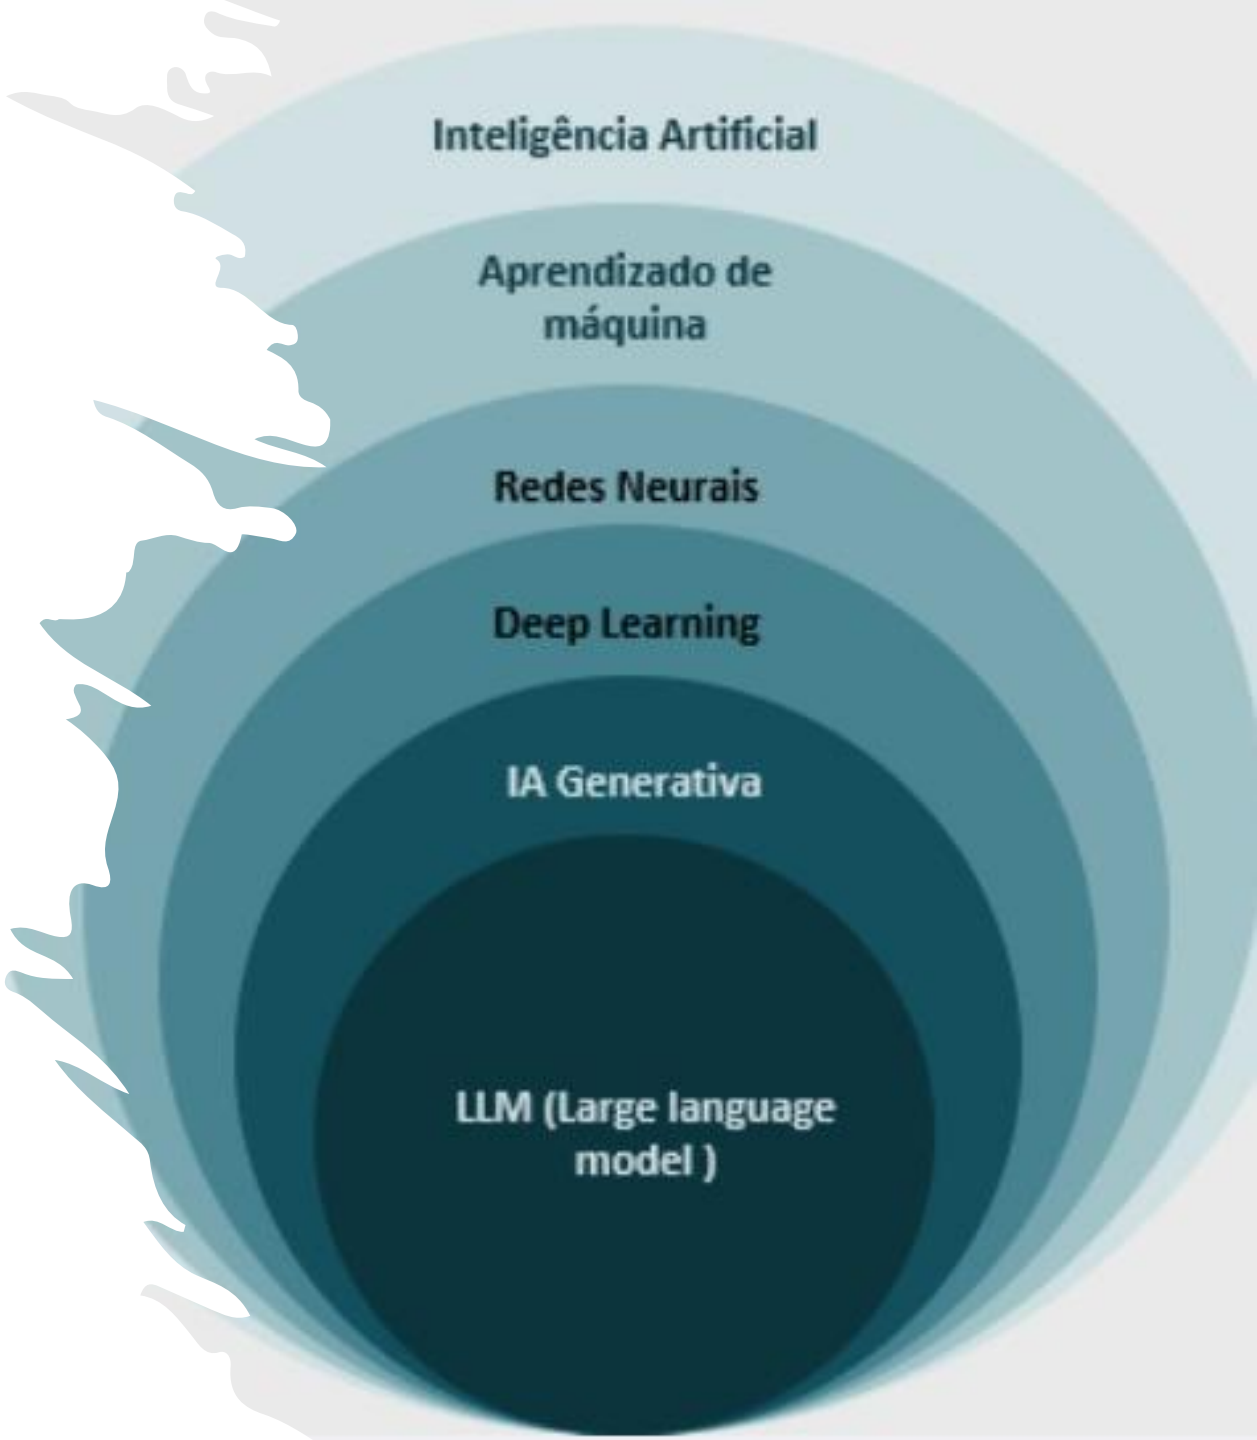

IA Generativa

Aqui a IA não só analisa. Ela cria.

Ela gera:

- Texto
- Imagens
- Código
- Música

Exemplo:

ChatGPT, Midjourney, DALL·E

Não é só previsão. É criação baseada em padrões.

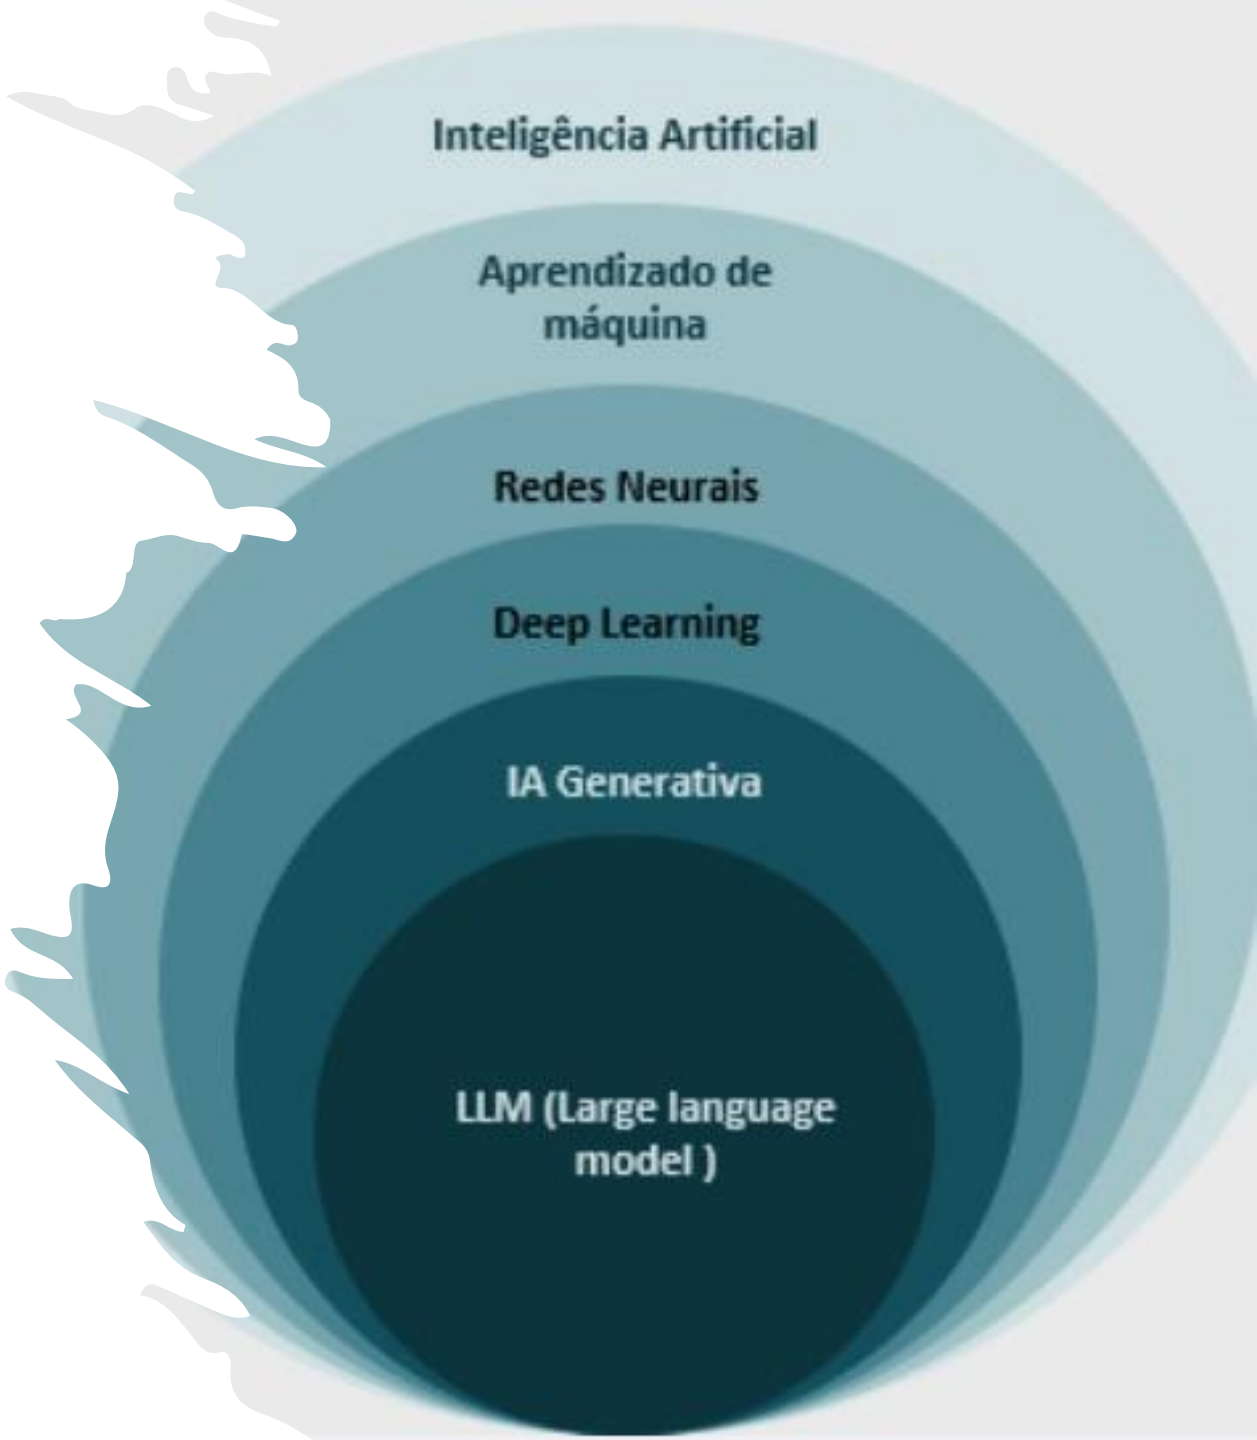

Large Language Models

Modelos treinados com enormes quantidades de texto para entender e gerar linguagem.

Eles fazem:

- Responder perguntas
- Escrever textos
- Traduzir
- Programar

- **Exemplo:**
  ChatGPT

Eles não “sabem”. Eles preveem a próxima palavra... absurdamente bem.

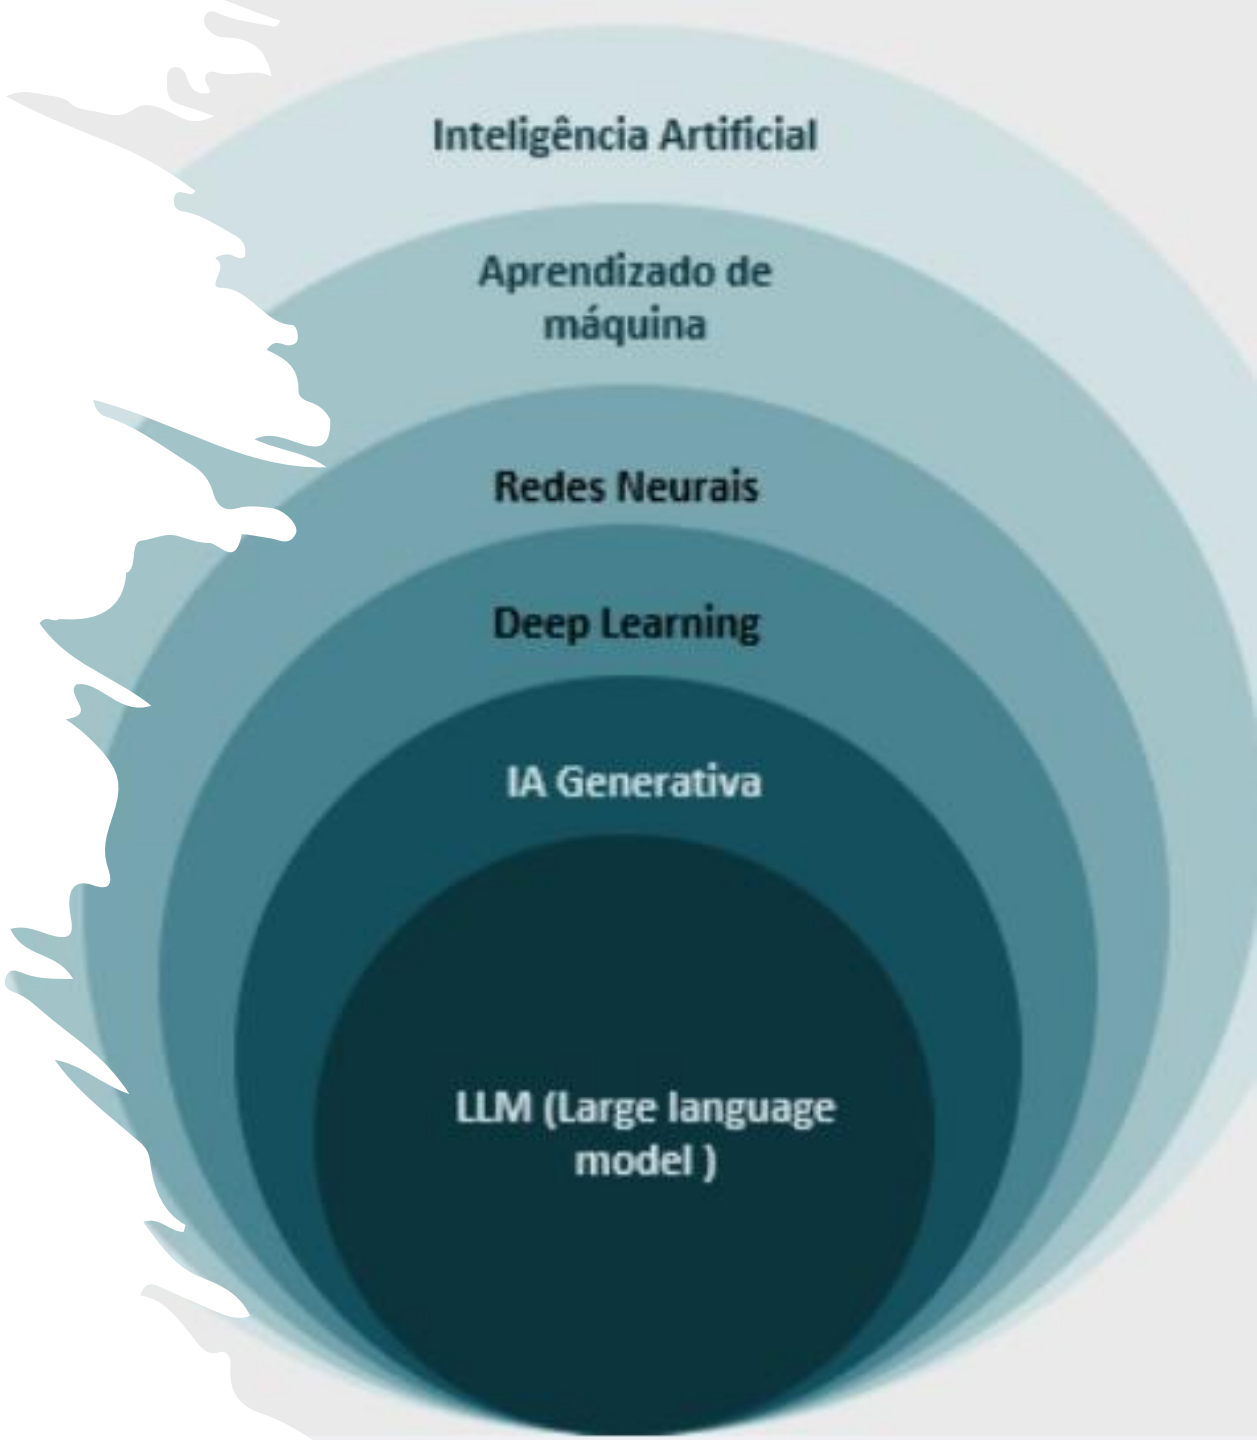

Qual a diferença?

“Se eu pudesse usar apenas uma palavra para descrever a IA pós-2020, seria ***escala***.

Os modelos de IA por trás de aplicativos como ChatGPT, Gemini do Google e Midjourney estão em tal escala que estão consumindo uma parte não trivial da eletricidade do mundo, e corremos o risco de ficar sem dados de internet disponíveis publicamente para treiná-los”.

Chip Huyen

Dois pontos...

O aumento dos modelos de IA tem duas grandes consequências.

Primeiro, os modelos de IA estão se tornando mais poderosos e capazes de mais tarefas, **permitindo mais aplicativos.**

Mais pessoas e equipes aproveitam a IA para aumentar a produtividade, criar valor econômico e melhorar a qualidade de vida.

Dois pontos...

Em segundo lugar, ***o treinamento de grandes modelos de linguagem (LLMs) requer dados, recursos de computação e talentos especializados que apenas algumas organizações podem pagar.***

Modelo como Serviço

Isso levou ao surgimento do *modelo como serviço*: os modelos desenvolvidos por essas poucas organizações são disponibilizados para que outras usem como um serviço.

Qualquer pessoa que deseje aproveitar a IA para criar aplicativos agora pode usar esses modelos para fazê-lo sem ter que investir de antemão na construção de um modelo.

Oportunidades

Ainda estamos no início da revolução...

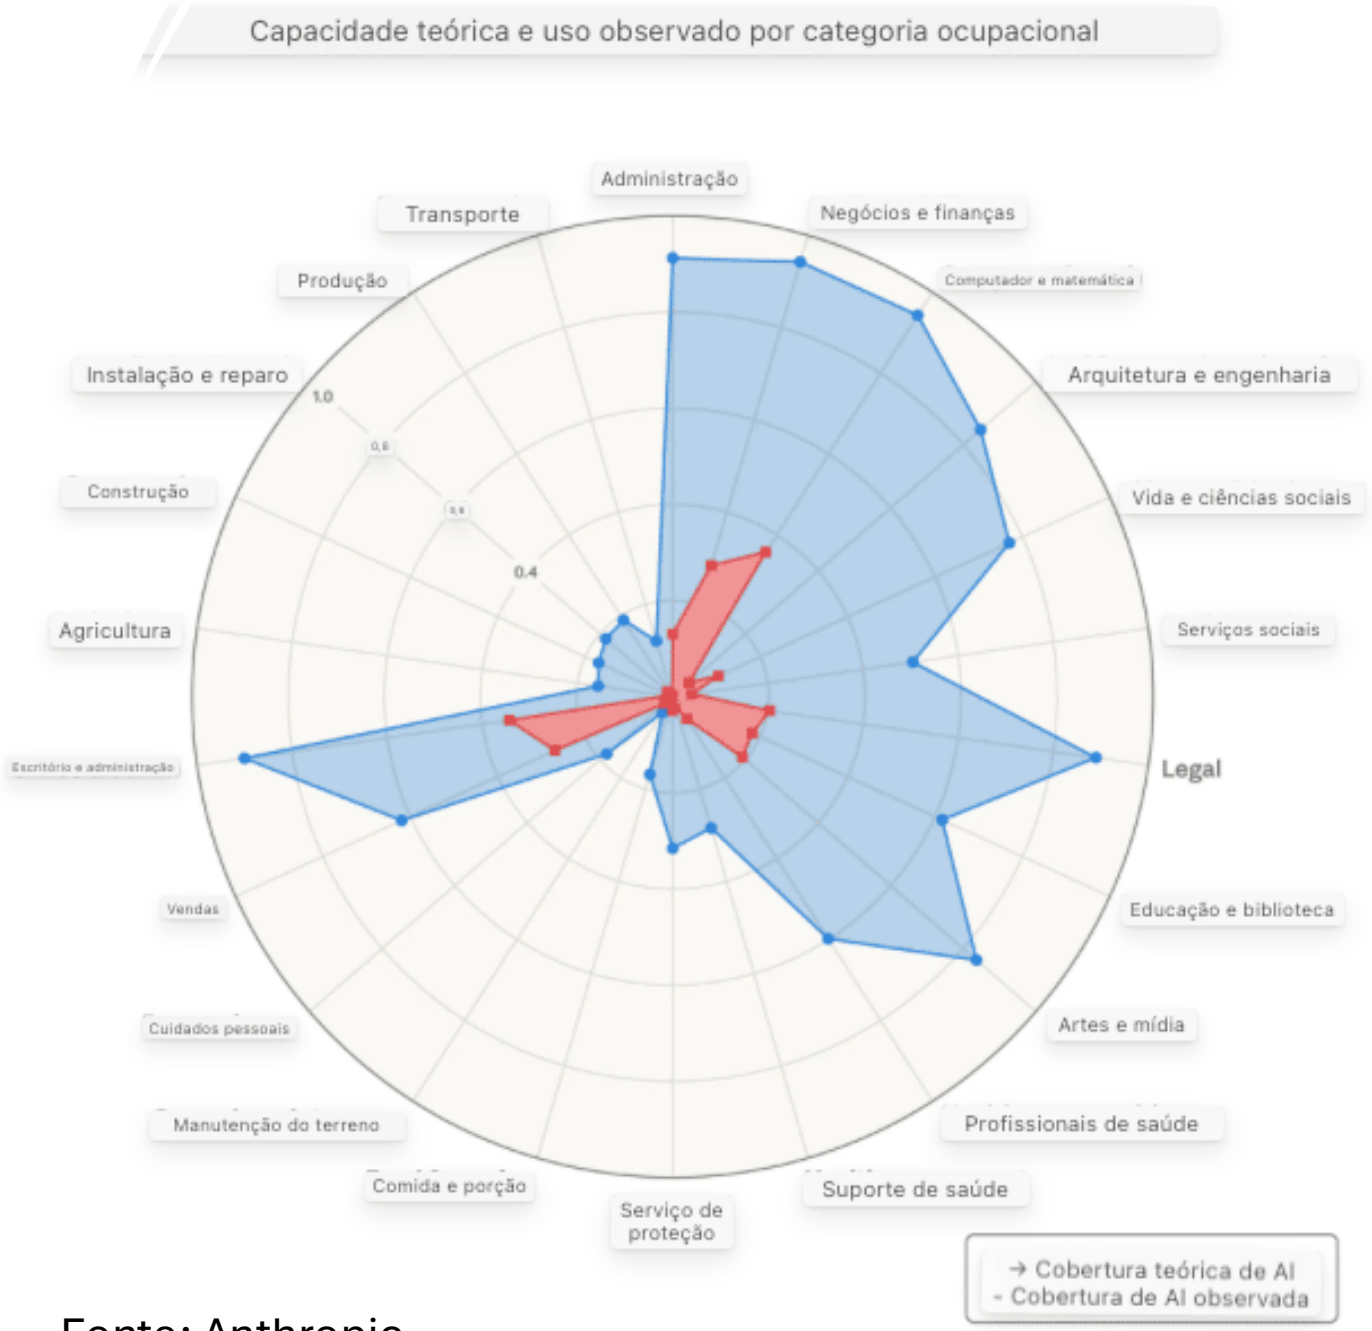

Fonte: Anthropic

Resumindo até aqui...

Em resumo, a demanda por aplicativos de IA aumentou, enquanto a barreira de entrada para a construção de aplicativos de IA diminuiu. Isso transformou a engenharia de IA - o processo de construção de aplicativos sobre modelos prontamente disponíveis - em uma das disciplinas de engenharia que mais crescem.

De Modelos de Linguagem a Grandes Modelos de Linguagem

Um *modelo de linguagem* codifica informações estatísticas sobre um ou mais idiomas.

Intuitivamente, essa informação nos diz a probabilidade de uma palavra aparecer em um determinado contexto.

Por exemplo, dado o contexto

“Minha cor favorita é __”,

um modelo de linguagem que codifica o inglês deve prever “azul” com mais frequência do que “carro”.

De Modelos de Linguagem a Grandes Modelos de Linguagem

A natureza estatística das línguas foi descoberta há séculos.

Na história de 1905 [“A Aventura dos Homens Dançantes”,](#) Sherlock Holmes aproveitou informações estatísticas simples do inglês para decodificar sequências de figuras misteriosas.

Como a letra mais comum em inglês é *E*, Holmes deduziu que a figura de palito mais comum deve significar *E*.

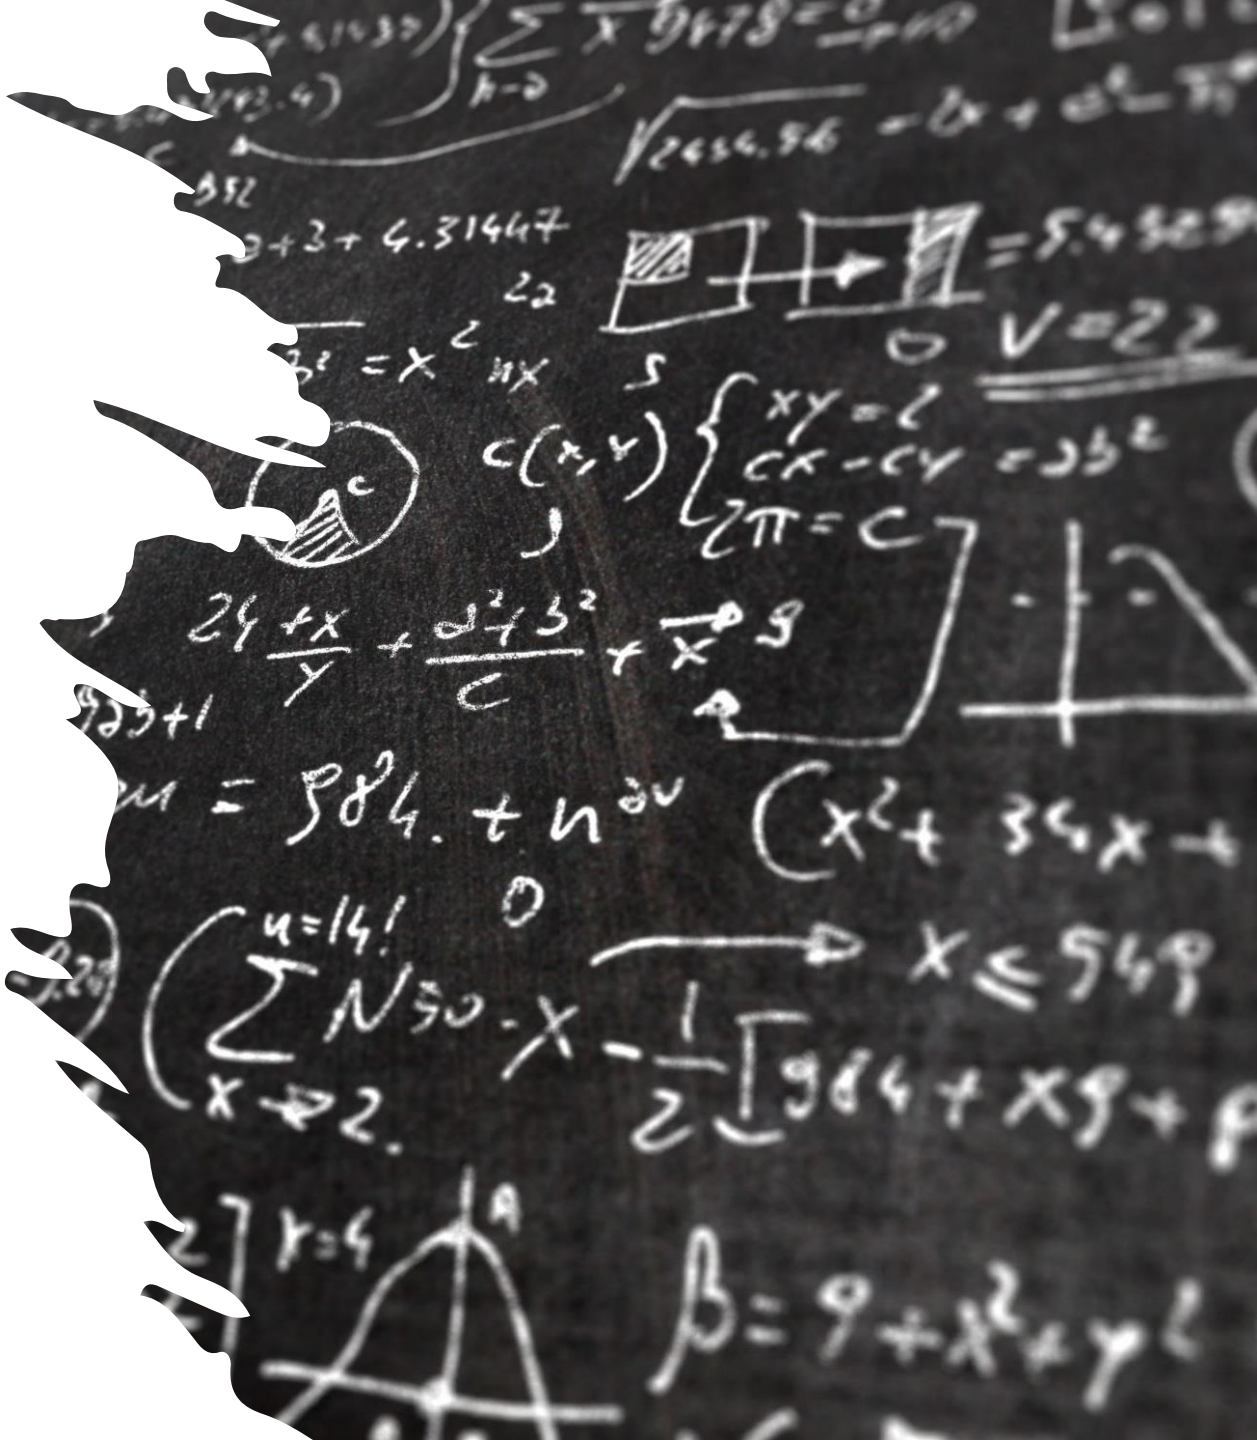

De Modelos de Linguagem a Grandes Modelos de Linguagem

Mais tarde, Claude Shannon usou estatísticas mais sofisticadas para decifrar as mensagens dos inimigos durante a Segunda Guerra Mundial.

Seu trabalho sobre como modelar o inglês foi publicado em seu artigo histórico de 1951 “Prediction and Entropy of Printed English”.

Muitos conceitos introduzidos neste artigo, incluindo a entropia, ainda são usados para modelagem de linguagem hoje.

De Modelos de Linguagem a Grandes Modelos de Linguagem

A unidade básica de um modelo de linguagem é *o token*.

Um token pode ser um caractere, uma palavra ou uma parte de uma palavra (como -tion), dependendo do modelo.

O modelo GPT-4, por exemplo, divide a frase abaixo em 9 tokens:

De Modelos de Linguagem a Grandes Modelos de Linguagem

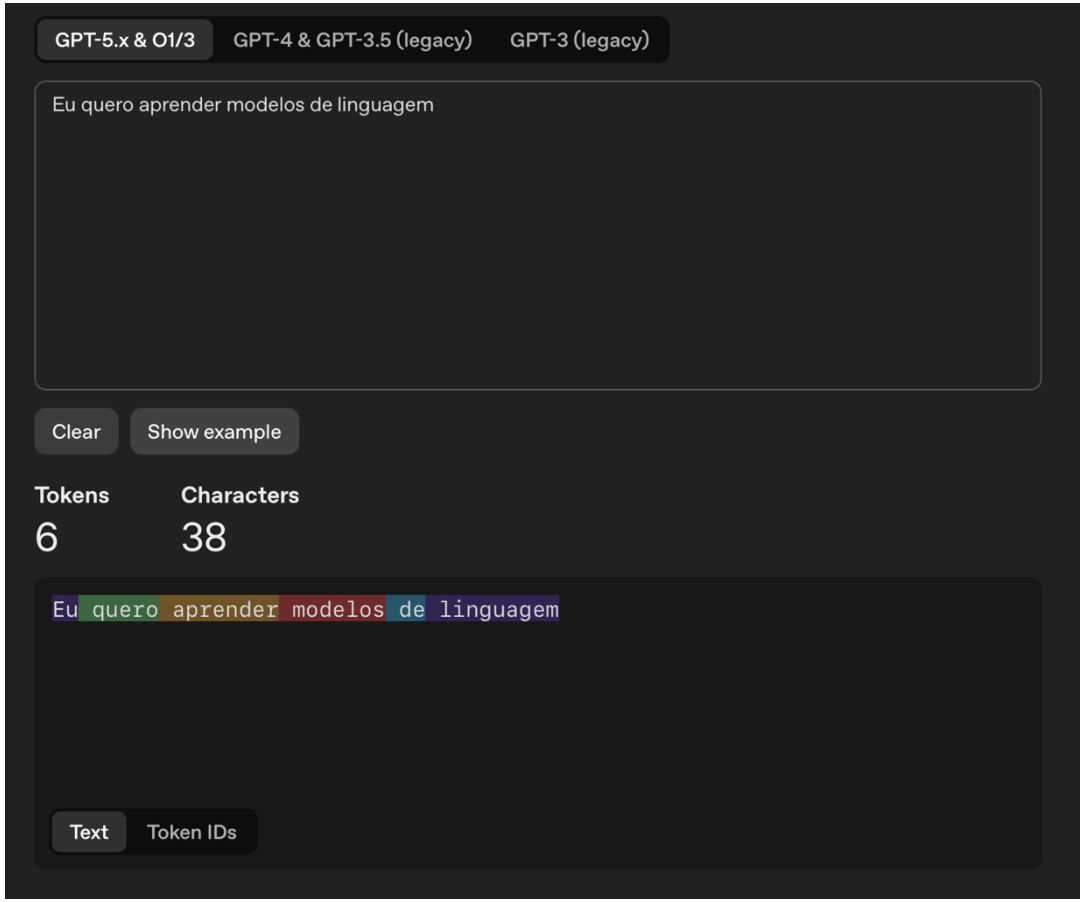

https://platform.openai.com/tokenizer

De Modelos de Linguagem a Grandes Modelos de Linguagem

O processo de dividir o texto original em tokens é chamado *de tokenização*.

Para o GPT-4, um token médio é aproximadamente ¾ do tamanho de uma palavra, por exemplo.

Então, 100 tokens seriam aproximadamente 75 palavras.

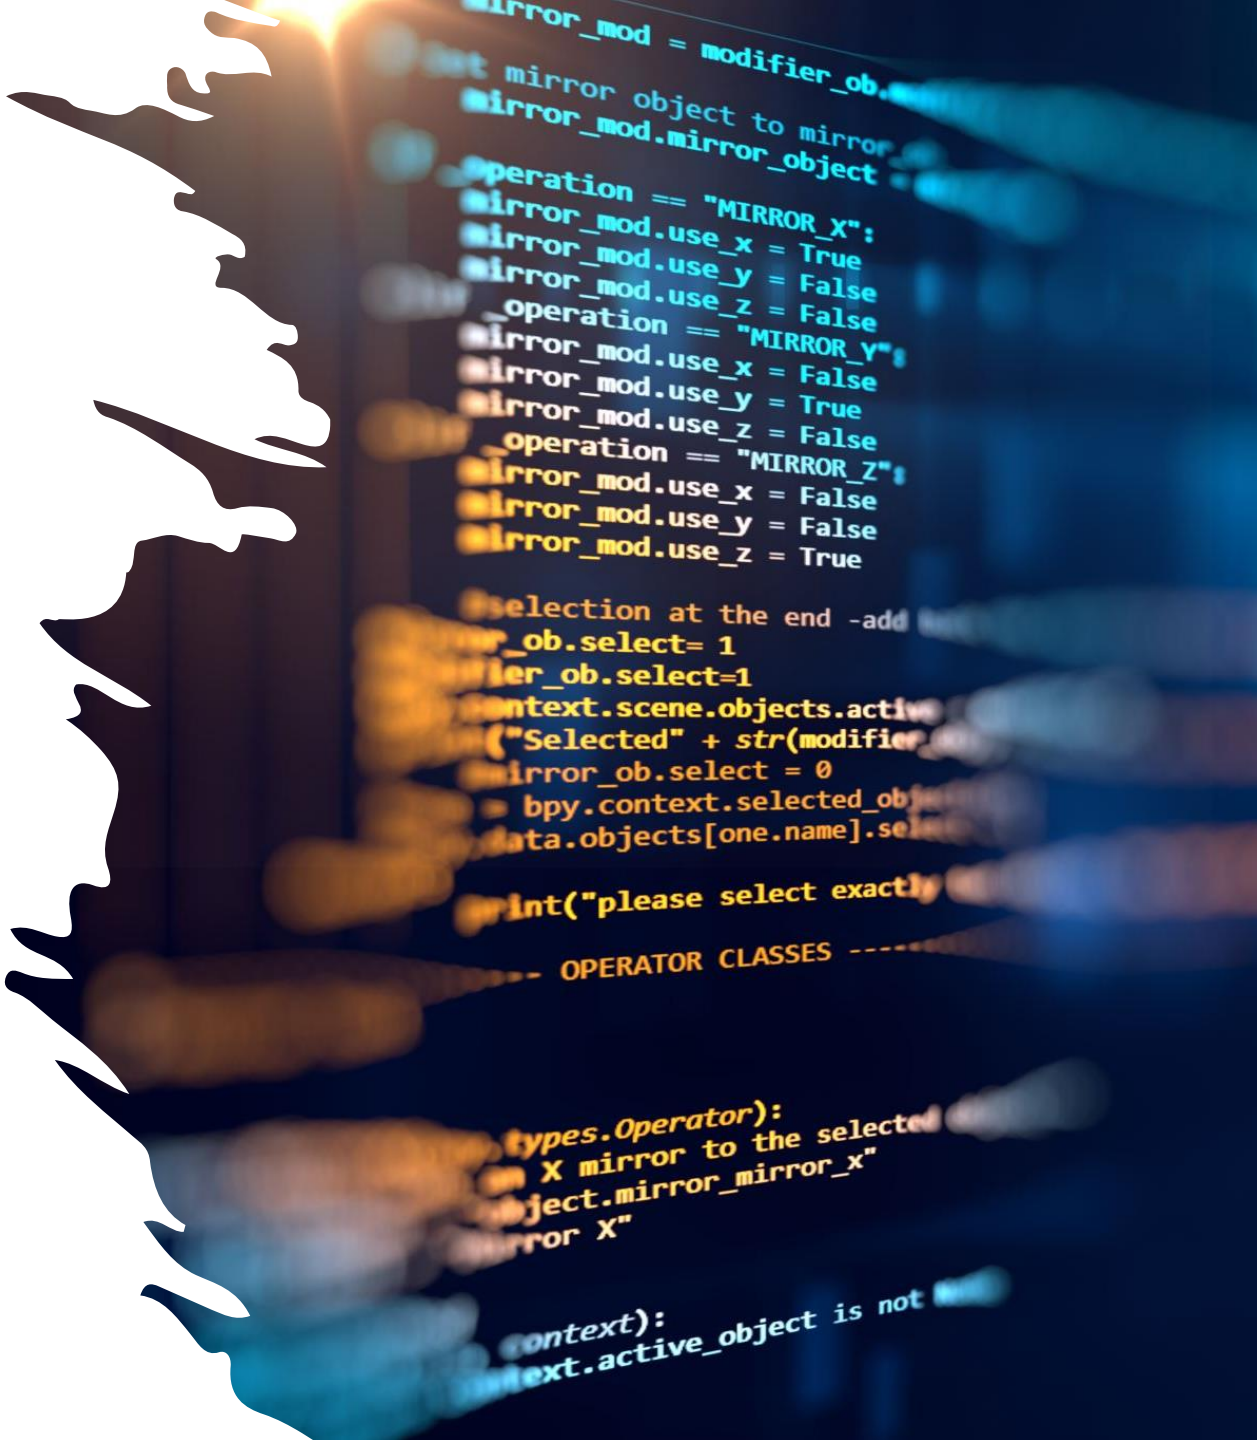

De Modelos de Linguagem a Grandes Modelos de Linguagem

O conjunto de todos os tokens com os que um modelo pode trabalhar é o *vocabulário* do modelo.

Você pode usar um pequeno número de tokens para construir um grande número de palavras distintas, semelhante a como você pode usar algumas letras no alfabeto para construir muitas palavras.

O modelo Mixtral 8x7B tem um tamanho de vocabulário de 32.000.

O tamanho do vocabulário do GPT-4 é 100.256.

O método de tokenização e o tamanho do vocabulário são decididos pelos desenvolvedores do modelo.

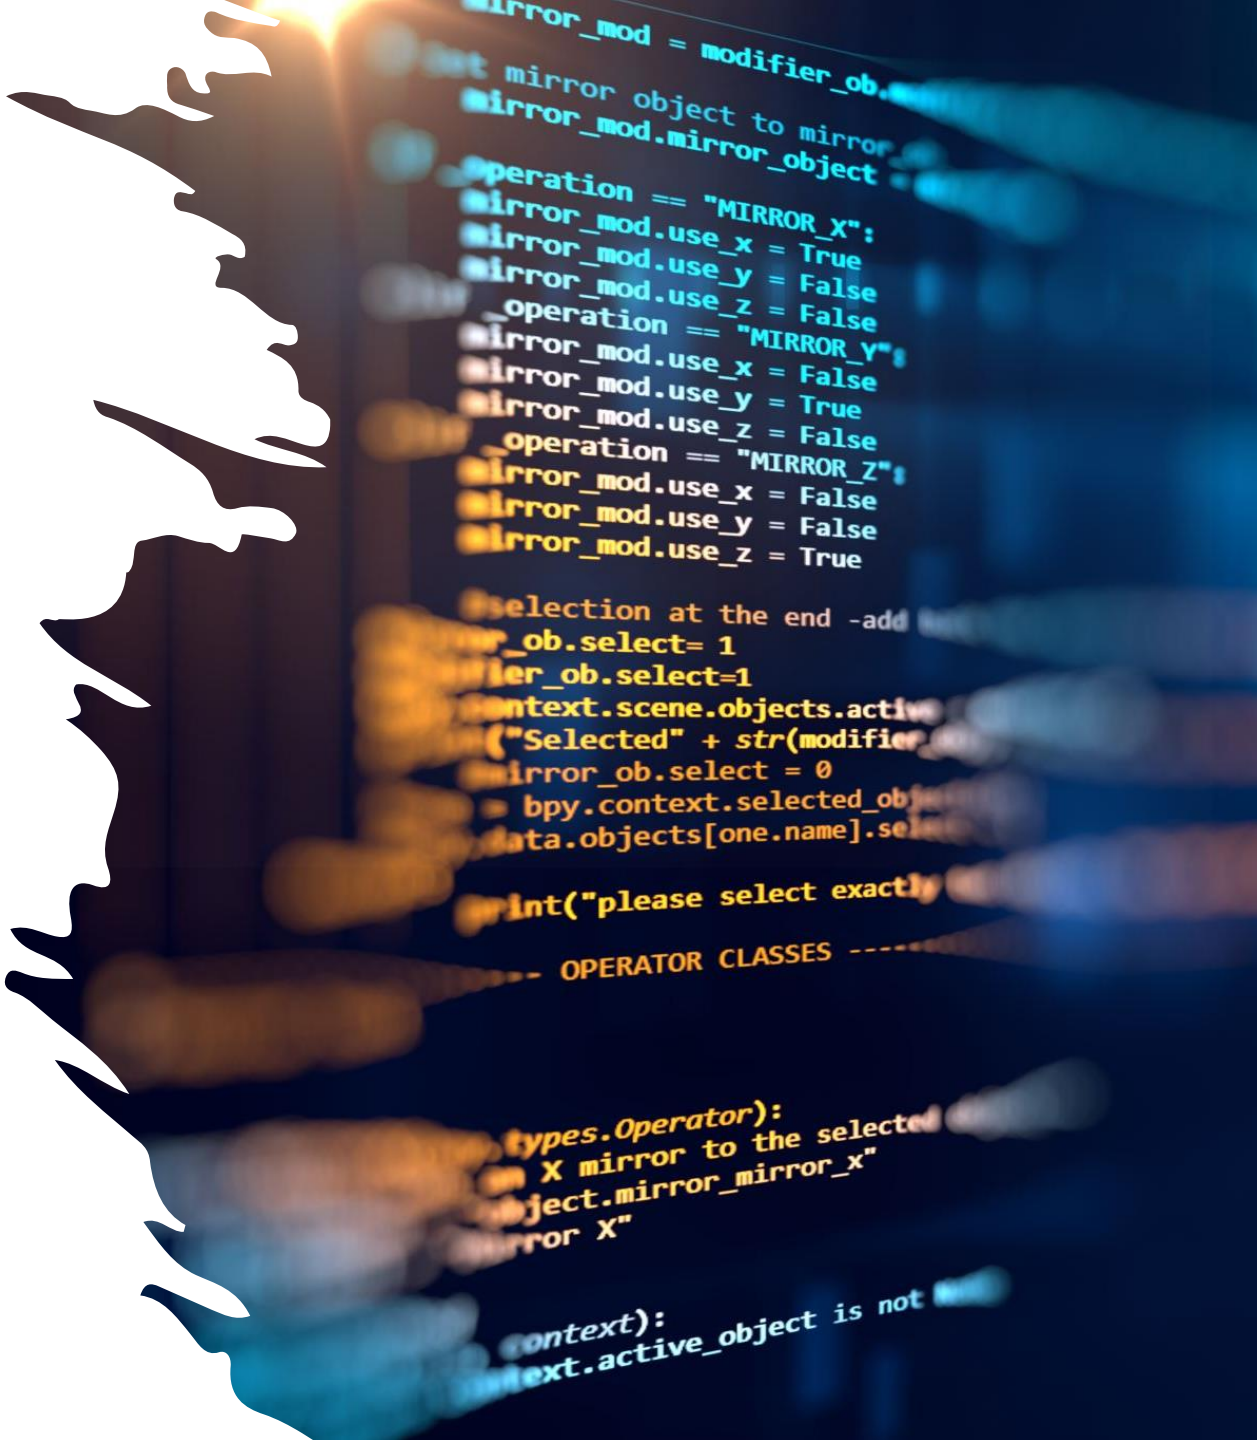

Por que os modelos de linguagem usam *token* como sua unidade em vez de *palavra* ou *caractere*?

- Comparados aos caracteres, os tokens permitem que o modelo divida palavras em componentes significativos. Por exemplo, “cooking” pode ser dividido em “cook” e “ing” com ambos os componentes carregando algum significado da palavra original.
- Como há menos tokens exclusivos do que palavras únicas, isso reduz o tamanho do vocabulário do modelo, tornando-o mais eficiente;
- Os tokens também ajudam o modelo a processar palavras desconhecidas. Por exemplo, uma palavra inventada como “chatgpting” poderia ser dividida em “chatgpt” e “ing”, ajudando o modelo a entender sua estrutura. Tokens equilibram com menos unidades do que palavras, mantendo mais significado do que caracteres individuais.

De Modelos de Linguagem a Grandes Modelos de Linguagem

Existem dois tipos principais de modelos de linguagem: *modelos de linguagem mascarados* e *modelos de linguagem autorregressiva*.

Eles diferem com base em quais informações podem usar para prever um *token*.

De Modelos de Linguagem a Grandes Modelos de Linguagem

Um modelo de linguagem mascarada é treinado para prever tokens ausentes em qualquer lugar de uma sequência, *usando o contexto de antes e depois dos tokens ausentes*.

Em essência, um modelo de linguagem mascarada é treinado para ser capaz de preencher o espaço em branco.

Por exemplo, dado o contexto,

“Meu __ favorito é azul”, um modelo de linguagem mascarada deve prever que o espaço em branco é provavelmente “cor”.

Um exemplo bem conhecido de um modelo de linguagem mascarada são as representações bidirecionais de codificadores de transformadores, ou BERT.

De Modelos de Linguagem a Grandes Modelos de Linguagem

Um modelo de linguagem autorregressiva é treinado para prever o próximo token em uma sequência, *usando apenas os tokens anteriores*.

Ele prevê o que vem a seguir em “Minha cor favorita é __.”

Um modelo autorregressivo pode gerar continuamente um token após o outro.

Hoje, os modelos de linguagem autorregressiva são os modelos de escolha para geração de texto e, por esse motivo, são muito mais populares do que os modelos de linguagem mascarada.

De Modelos de Linguagem a Grandes Modelos de Linguagem

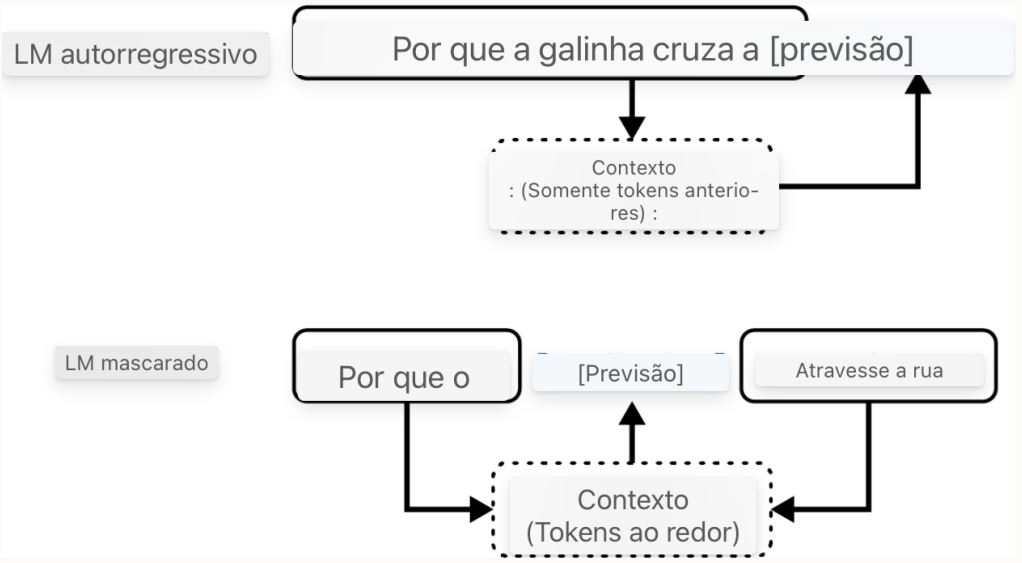

Figura 1-2. Modelo de linguagem autorregressiva e modelo de linguagem mascarada.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- As saídas dos modelos de linguagem são abertas.
- Um modelo de linguagem pode usar seu vocabulário fixo e finito para construir saídas infinitas possíveis.
- Um modelo que pode gerar saídas abertas é chamado *de generativo*, daí o termo *IA generativa*.
- Você pode pensar em um modelo de linguagem como uma *máquina de conclusão*: dado um texto (prompt), ele tenta completar esse texto.
- Aqui está um exemplo:

De Modelos de Linguagem a Grandes Modelos de Linguagem

- As saídas dos modelos de linguagem são abertas.
- Um modelo de linguagem pode usar seu vocabulário fixo e finito para construir saídas infinitas possíveis.
- Um modelo que pode gerar saídas abertas é chamado *de generativo*, daí o termo *IA generativa*.
- Você pode pensar em um modelo de linguagem como uma *máquina de conclusão*: dado um texto (prompt), ele tenta completar esse texto.
- Aqui está um exemplo:

De Modelos de Linguagem a Grandes Modelos de Linguagem

```
Prompt (from user): "To be or not to be"
Completion (from language model): ", that is the question."
```

De Modelos de Linguagem a Grandes Modelos de Linguagem

Por mais simples que pareça, a conclusão é incrivelmente poderosa.

Muitas tarefas, incluindo tradução, resumo, codificação e resolução de problemas matemáticos, podem ser enquadradas como tarefas de conclusão.

Por exemplo, dado o prompt:

“Como você está em francês é ...”,

um modelo de idioma pode ser capaz de completá-lo com:

“Comment ça va”, traduzindo efetivamente de um idioma para outro.

De Modelos de Linguagem a Grandes Modelos de Linguagem

```
Question: Is this email likely spam? Here’s the email: <email c
Answer:
```

Um modelo de linguagem pode ser capaz de completá-lo com: “Spam provavelmente”.

O que transforma esse modelo de idioma em um classificador de spam.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- A modelagem de linguagem é apenas um dos muitos algoritmos de ML.

- Existem também modelos para detecção de objetos, modelagem de tópicos, sistemas de recomendação, previsão do tempo, previsão do preço das ações, etc.

- O que é especial sobre os modelos de linguagem que os tornaram o centro da abordagem de dimensionamento que causou o momento ChatGPT?

De Modelos de Linguagem a Grandes Modelos de Linguagem

- A resposta é que os modelos de linguagem podem ser treinados usando *autosupervisão*, enquanto muitos outros modelos exigem *supervisão*.

- Supervisão refere-se ao processo de treinamento de algoritmos de ML usando dados rotulados, que podem ser caros e lentos para obter.

- A autosupervisão ajuda a superar esse gargalo de rotulagem de dados para criar conjuntos de dados maiores para os modelos aprenderem, permitindo efetivamente que os modelos aumentem.

- Veja como:

De Modelos de Linguagem a Grandes Modelos de Linguagem

- Com supervisão, você rotula exemplos para mostrar os comportamentos que deseja que o modelo aprenda e, em seguida, treina o modelo nesses exemplos.

- Uma vez treinado, o modelo pode ser aplicado a novos dados.

- Por exemplo, para treinar um modelo de detecção de fraude, você usa exemplos de transações, cada uma rotulada como "fraude" ou "não fraude".

- Uma vez que o modelo aprende com esses exemplos, você pode usar esse modelo para prever se uma transação é fraudulenta.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- O sucesso dos modelos de IA na década de 2010 estava na supervisão.
- O modelo que iniciou a revolução do aprendizado profundo, AlexNet (Krizhevsky et al., 2012), foi supervisionado.
- Foi treinado para aprender a classificar mais de 1 milhão de imagens no conjunto de dados ImageNet.
- Ele classificou cada imagem em uma das 1.000 categorias, como “carro”, “balão” ou “macaco”.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- Uma desvantagem da supervisão é que a rotulagem de dados é cara e demorada.

- Se custasse 5 centavos para uma pessoa rotular uma imagem, custaria US$ 50.000 rotular um milhão de imagens para a ImageNet.

- Se você quiser que duas pessoas diferentes rotulem cada imagem - para que você possa verificar a qualidade do rótulo - custaria o dobro.

- Como o mundo contém muito mais de 1.000 objetos, para expandir os recursos dos modelos para trabalhar com mais objetos, você precisaria adicionar rótulos de mais categorias.

- Para escalar até 1 milhão de categorias, o custo de rotulagem sozinho aumentaria para US$ 50 milhões.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- Rotular objetos do cotidiano é algo que a maioria das pessoas pode fazer sem treinamento prévio.
- Portanto, pode ser feito de forma relativamente barata. No entanto, nem todas as tarefas de rotulagem são tão simples.
- Gerar traduções em latim para um modelo de inglês para latim é mais caro.
- Rotular se uma tomografia computadorizada mostra sinais de câncer seria astronômico.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- A autosupervisão ajuda a superar o gargalo de rotulagem de dados.

- Na autosupervisão, em vez de exigir rótulos explícitos, o modelo pode inferir rótulos a partir dos dados de entrada.

- A modelagem de linguagem é autosupervisionada porque cada sequência de entrada fornece tanto os rótulos (tokens a serem previstos) quanto os contextos que o modelo pode usar para prever esses rótulos.

De Modelos de Linguagem a Grandes Modelos de Linguagem

- O aprendizado autosupervisionado significa que os modelos de linguagem podem aprender com sequências de texto sem exigir qualquer rotulagem.

- Como as sequências de texto estão por toda parte - em livros, postagens de blog, artigos e comentários do Reddit - é possível construir uma enorme quantidade de dados de treinamento, permitindo que os modelos de linguagem sejam dimensionados para se tornarem LLMs.

Dos LLMs aos “Modelos de Fundação”

- Embora os modelos de linguagem sejam capazes de tarefas incríveis, eles são limitados ao texto.
- Como humanos, percebemos o mundo não apenas através da linguagem, mas também através da visão, audição, toque e muito mais.
- Ser capaz de processar dados além do texto é essencial para que a IA opere no mundo real.
- Por esse motivo, os modelos de linguagem estão sendo estendidos para incorporar mais modalidades de dados.
- GPT-4V e Claude 3 podem entender imagens e textos.
- Alguns modelos até entendem vídeos, ativos 3D, estruturas de proteínas e assim por diante.
- Incorporar mais modalidades de dados em modelos de linguagem os torna ainda mais poderosos.

Dos LLMs aos “Modelos de Fundação”

- Embora muitas pessoas ainda chamem Gemini e GPT-4V de LLMs, eles são melhor caracterizados como modelos de fundação.

- A palavra fundação significa tanto a importância desses modelos em aplicações de IA quanto o fato de que eles podem ser construídos para diferentes necessidades.

Dos LLMs aos “Modelos de Fundação”

- Os modelos de fundação marcam um avanço na estrutura tradicional da pesquisa de IA.
- Por muito tempo, a pesquisa de IA foi dividida por modalidades de dados.
- O processamento de linguagem natural (PNL) lida apenas com texto.
- A visão computacional lida apenas com visão. Modelos somente de texto podem ser usados para tarefas como tradução e detecção de spam.
- Modelos somente de imagem podem ser usados para detecção de objetos e classificação de imagens.
- Modelos somente de áudio podem lidar com reconhecimento de fala (fala para texto, ou STT) e síntese de fala (texto para fala, ou TTS).

Dos LLMs aos “Modelos de Fundação”

- Um modelo que pode funcionar com mais de uma modalidade de dados também é chamado de modelo multimodal.

- Um modelo multimodal generativo também é chamado de grande modelo multimodal (LMM).

- Se um modelo de linguagem gera o próximo token condicionado a tokens somente de texto, um modelo multimodal gera o próximo token condicionado a tokens de texto e imagem, ou quaisquer modalidades que o modelo suporte.

Dos LLMs aos “Modelos de Fundação”

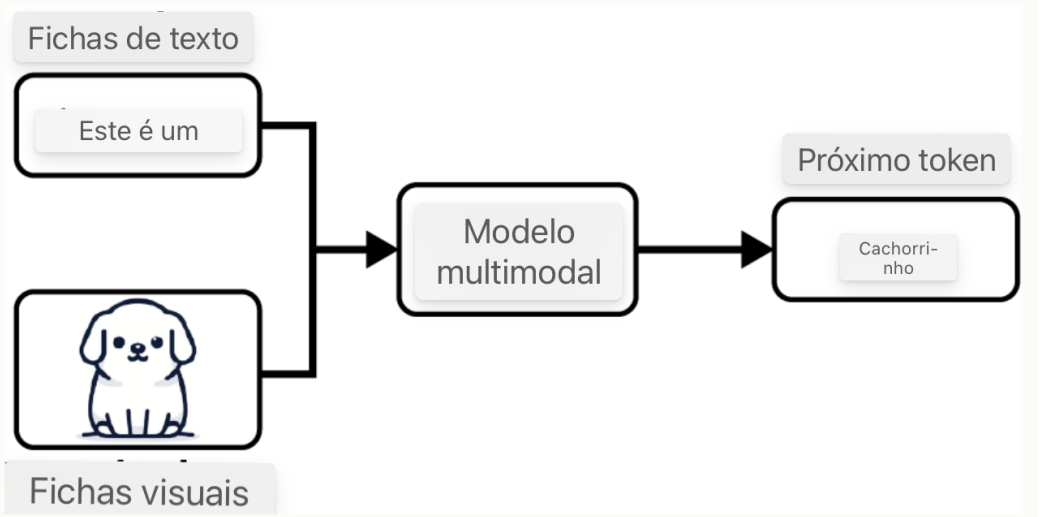

Figura 1-3. Um modelo multimodal pode gerar o próximo token usando informações de tokens de texto e visuais.

Casos de Uso

- Programação
- Análise de Dados
- Suporte ao Cliente
- Cópia de Marketing
- Pesquisa
- Web Design
- Arte

Casos de Uso

Figura 1-4. A gama de tarefas no benchmark Super-NaturalInstructions (Wang et al., 2022).